

# コンピュータグラフィクス論

## - モデリング (3) -

2025年5月1日

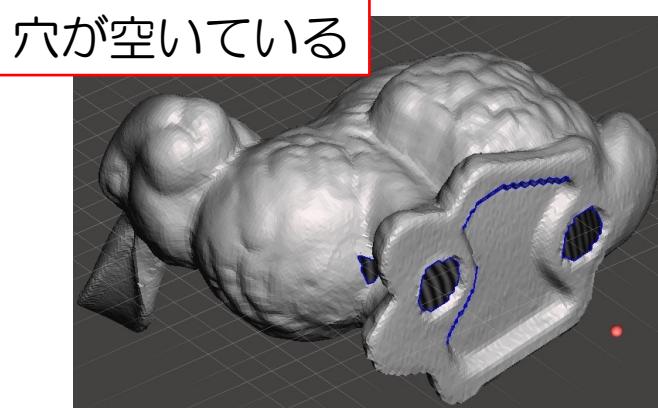
高山 健志

# ソリッドモデリング

# ソリッドモデルとは

- 3D 空間の任意の位置で、モデルの“内側”と“外側”が定義できるもの

ソリッドでないケース

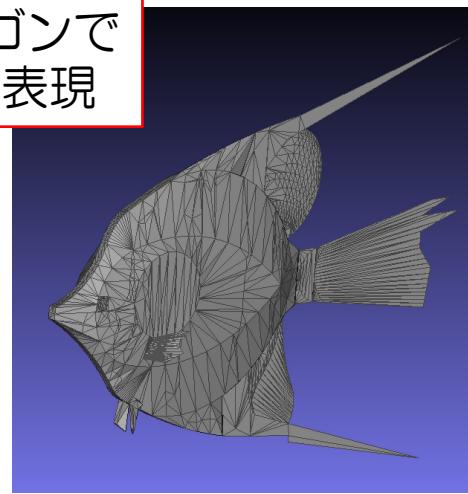


- 主な用途

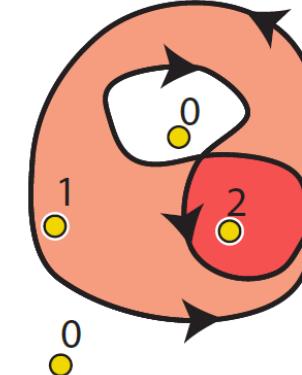
3D プリント



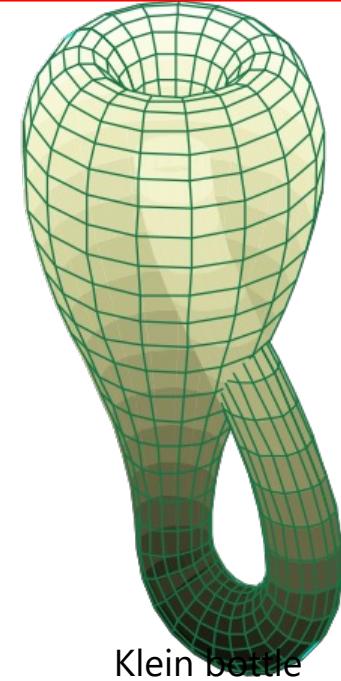
一枚のポリゴンで  
薄い形状を表現



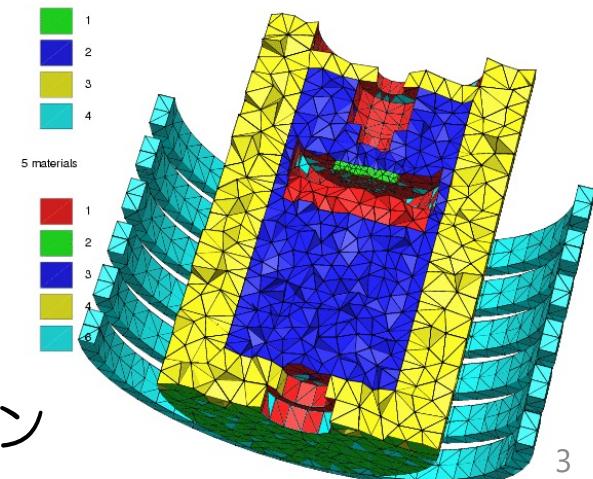
向き付け不可能



自己交差している



Klein bottle



物理シミュレーション

# ソリッドモデルの predicate 関数

- 3D 座標  $\mathbf{p} \in \mathbb{R}^3$  がソリッドモデルの内部であれば true を、そうでなければ false を返す関数：

$$f(\mathbf{p}): \mathbb{R}^3 \mapsto \{ \text{true}, \text{false} \}$$

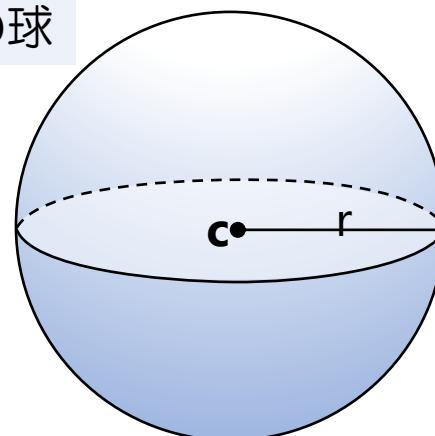
- モデル内部全体を表す集合：

$$\{ \mathbf{p} \mid f(\mathbf{p}) = \text{true} \} \subset \mathbb{R}^3$$

- 例：

点  $\mathbf{c}$  を中心とした半径  $r$  の球

$$f(\mathbf{p}) := \|\mathbf{p} - \mathbf{c}\| < r$$

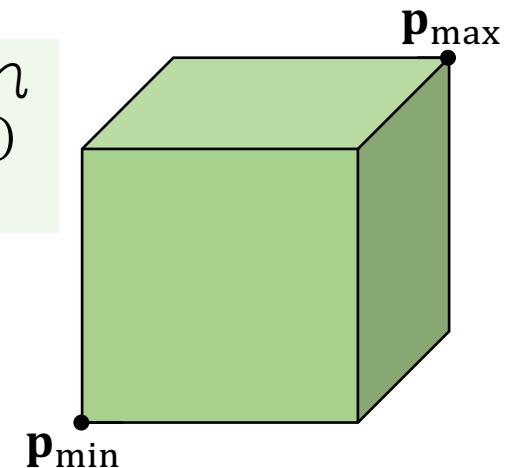


最小と最大の対角コーナーがそれぞれ  $(x_{\min}, y_{\min}, z_{\min})$  と  $(x_{\max}, y_{\max}, z_{\max})$  であるような直方体

$$f(x, y, z) := (x_{\min} < x < x_{\max})$$

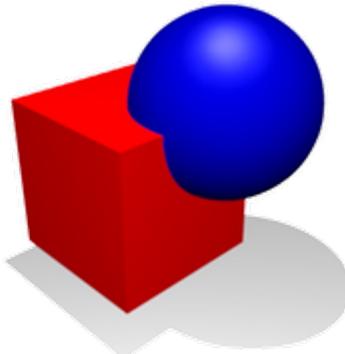
$$\wedge (y_{\min} < y < y_{\max})$$

$$\wedge (z_{\min} < z < z_{\max})$$



# Constructive Solid Geometry (Boolean演算)

和



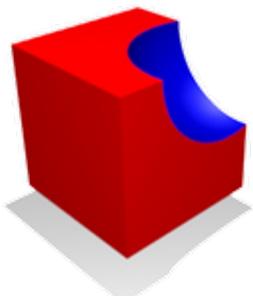
$$f_{A \cup B}(\mathbf{p}) := f_A(\mathbf{p}) \vee f_B(\mathbf{p})$$

積



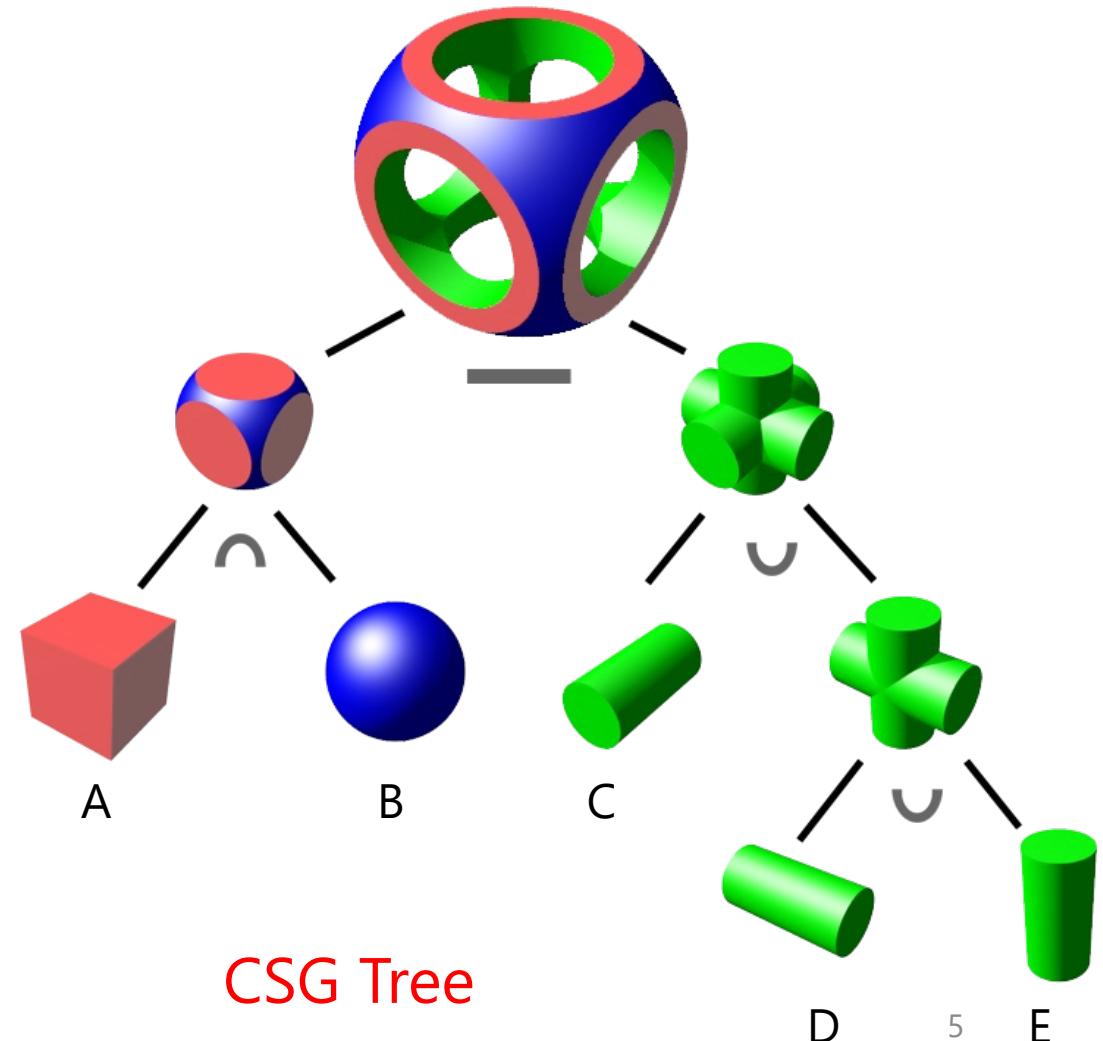
$$f_{A \cap B}(\mathbf{p}) := f_A(\mathbf{p}) \wedge f_B(\mathbf{p})$$

差



$$f_{A \setminus B}(\mathbf{p}) := f_A(\mathbf{p}) \wedge \neg f_B(\mathbf{p})$$

$$(A \cap B) \setminus (C \cup (D \cup E))$$



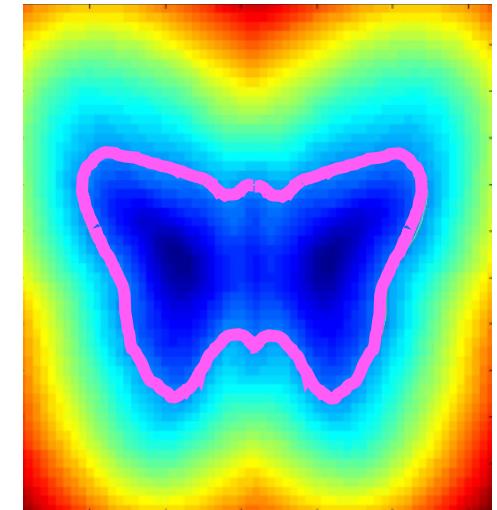
CSG Tree

# 符号付き距離場によるソリッドモデル表現

- **Signed Distance Function:** 3D座標から  
モデル表面までの最短距離

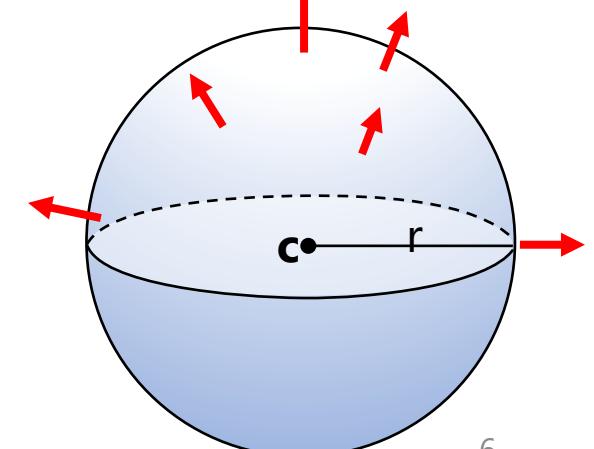
$$d(\mathbf{p}): \mathbb{R}^3 \mapsto \mathbb{R}$$

- 符号付き：内側では負、外側では正
- ソリッドモデルを表すpredicate:  
$$f(\mathbf{p}) := d(\mathbf{p}) < 0$$
- ゼロ等値面はモデル表面を表す：  
$$\{\mathbf{p} \mid d(\mathbf{p}) = 0\} \subset \mathbb{R}^3$$
- 「陰関数表現」 「ボリューム表現」
- 等値面の法線は勾配  $\nabla d(\mathbf{p})$  の方向と一致



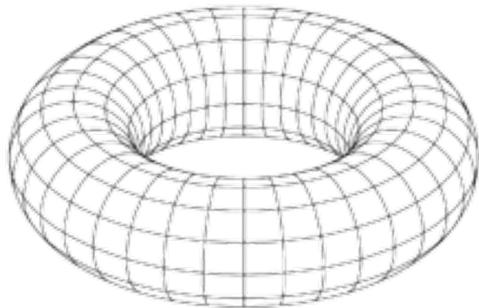
点  $\mathbf{c}$  を中心とした半径  $r$  の球

$$d(\mathbf{p}) := \|\mathbf{p} - \mathbf{c}\| - r$$



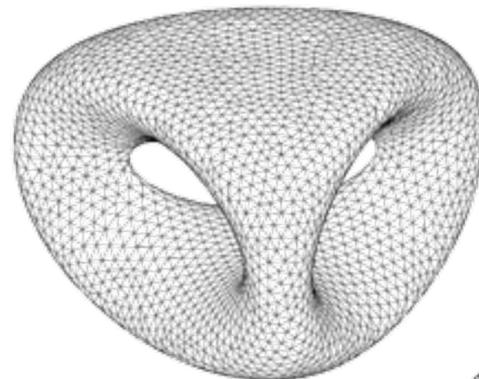
# 陰関数のデザイン例

必ずしも距離関数とは限らない

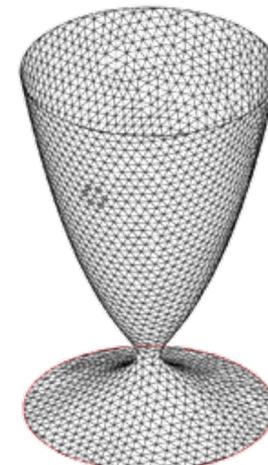


大半径  $R$ , 小半径  $a$  のトーラス

$$(x^2 + y^2 + z^2 + R^2 - a^2)^2 - 4R^2(x^2 + y^2) = 0$$



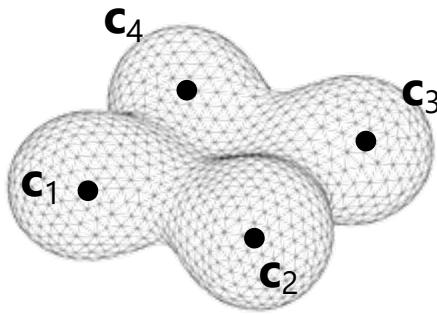
$$2y(y^2 - 3x^2)(1 - z^2) + (x^2 + y^2)^2 - (9z^2 - 1)(1 - z^2) = 0$$



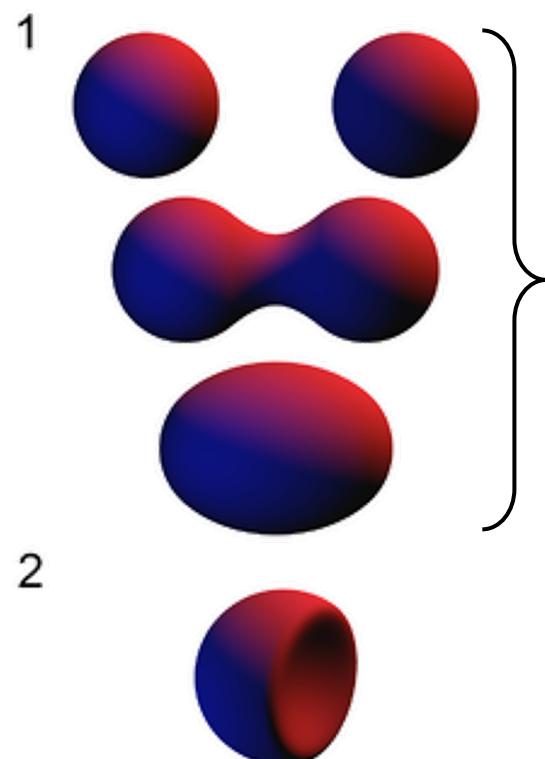
$$x^2 + y^2 - (\ln(z + 3.2))^2 - 0.02 = 0$$

# 陰関数のデザイン例：等電位面 (Metaball)

$$d_i(\mathbf{p}) = \frac{q_i}{\|\mathbf{p} - \mathbf{c}_i\|} - r_i$$



$$d(\mathbf{p}) = d_1(\mathbf{p}) + d_2(\mathbf{p}) + d_3(\mathbf{p}) + d_4(\mathbf{p})$$



$$d(\mathbf{p}) = d_1(\mathbf{p}) + d_2(\mathbf{p})$$

$$d(\mathbf{p}) = d_1(\mathbf{p}) - d_2(\mathbf{p})$$

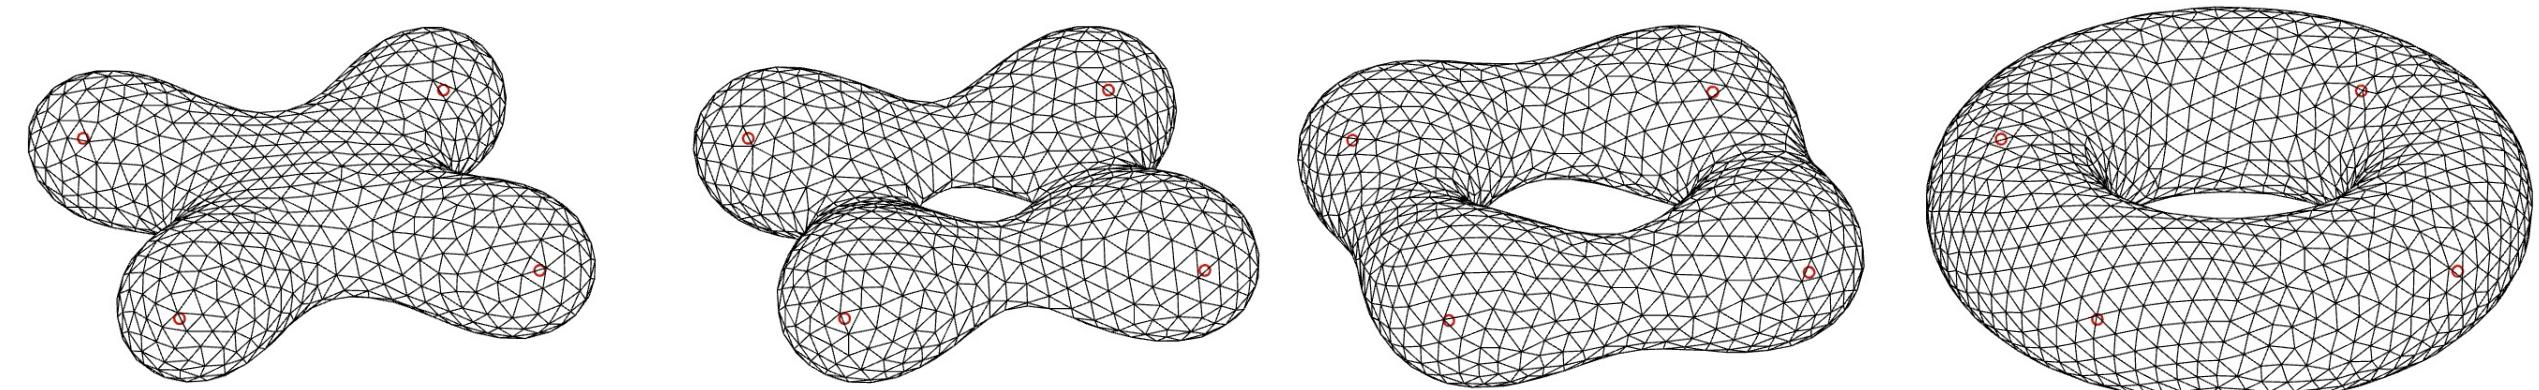
# Fast metaball rendering

## **GPU-based Fast Ray Casting for a Large Number of Metaballs**

Yoshihiro Kanamori, Zoltan Szego, Tomoyuki Nishita

The University of Tokyo

# 陰関数の線形補間によるモーフィング



$$d_1(\mathbf{p}) = 0$$

$$\frac{2}{3}d_1(\mathbf{p}) + \frac{1}{3}d_2(\mathbf{p}) = 0$$

$$\frac{1}{3}d_1(\mathbf{p}) + \frac{2}{3}d_2(\mathbf{p}) = 0$$

$$d_2(\mathbf{p}) = 0$$

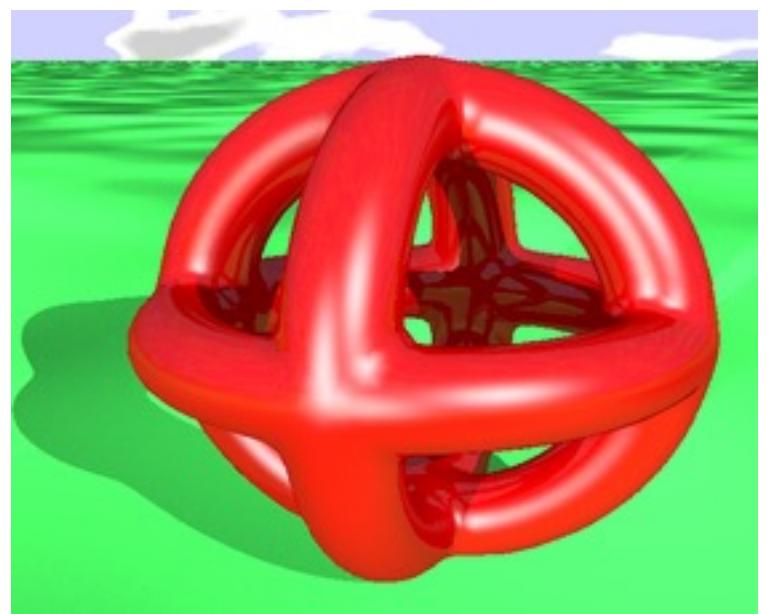
# 複数の陰関数を組み合わせたモデリング

$$F_1 = (x^2 + y^2 + z^2 + R^2 - a^2)^2 - 4R^2(x^2 + y^2) = 0$$

$$F_2 = (x^2 + y^2 + z^2 + R^2 - a^2)^2 - 4R^2(x^2 + z^2) = 0$$

$$F_3 = (x^2 + y^2 + z^2 + R^2 - a^2)^2 - 4R^2(y^2 + z^2) = 0$$

$$F(x, y, z) = F_1(x, y, z) \cdot F_2(x, y, z) \cdot F_3(x, y, z) - c = 0$$



# より高度なブレンディング

- 2つの陰関数をブレンドする際、それらの**勾配の向き**に応じてブレンド方法を変える



従来法  
(ただの和)



提案法



# 陰関数の性質を活用した3Dモデリングの例



ShapeShop v002

Demo Reel

# 陰関数の性質を活用した3Dモデリングの例



Sketching Interface  
for Modeling Internal  
Structure of 3D Shapes

# 陰関数の表示方法：Marching Cubes

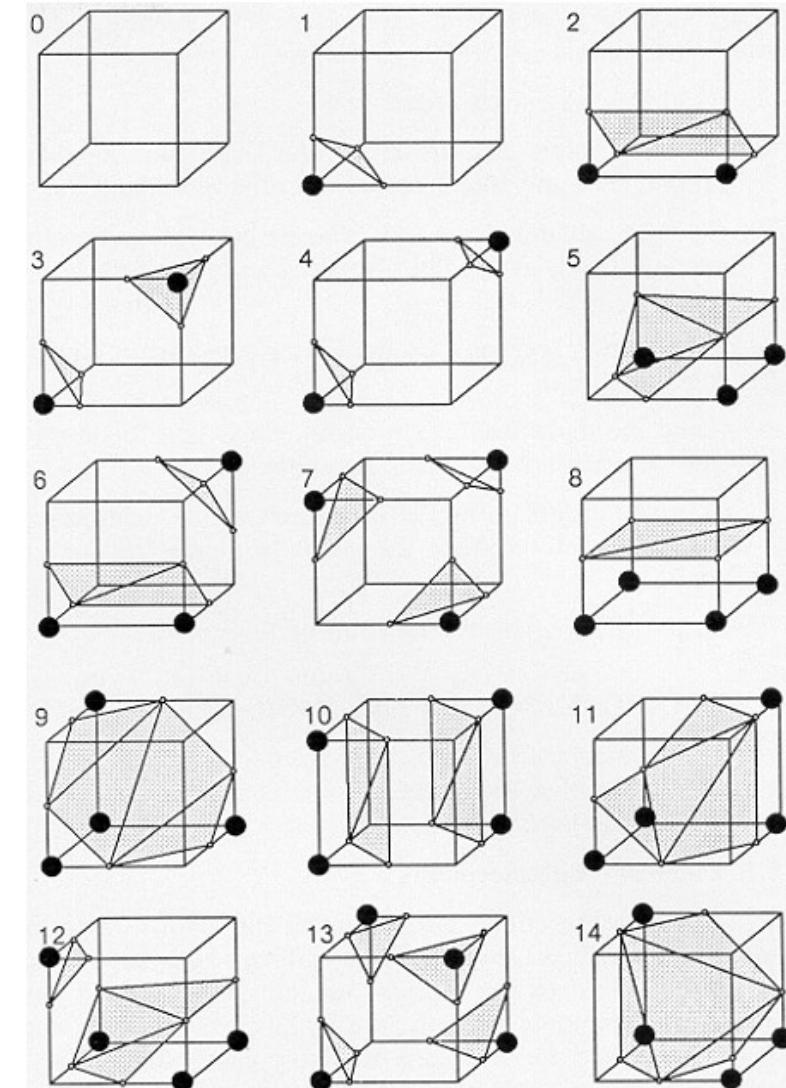
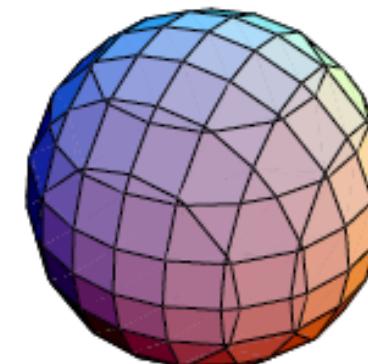
- 等値面を三角形メッシュとして抽出

- 立方体格子の各セルに対し、  
(1) 立方体の 8 頂点で関数値を計算

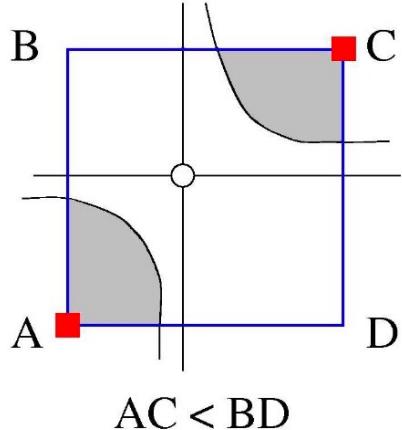
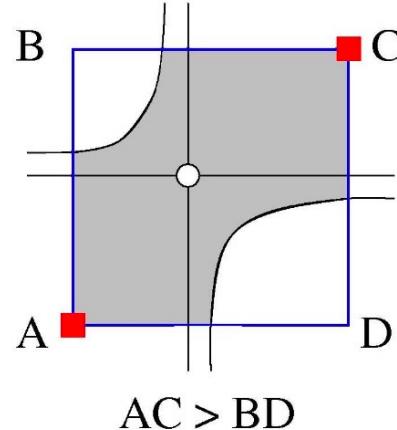
- (2) その正負のパターンから、  
生成する面のタイプを決定  
• 対称性から 15 通りに分類

- (3) 関数値の線形補間から  
面の位置を決定

(特許で縛られていたが、期限が切れた)

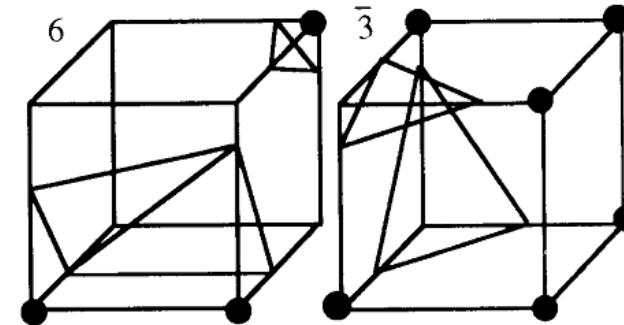


# Marching Cubes の曖昧性

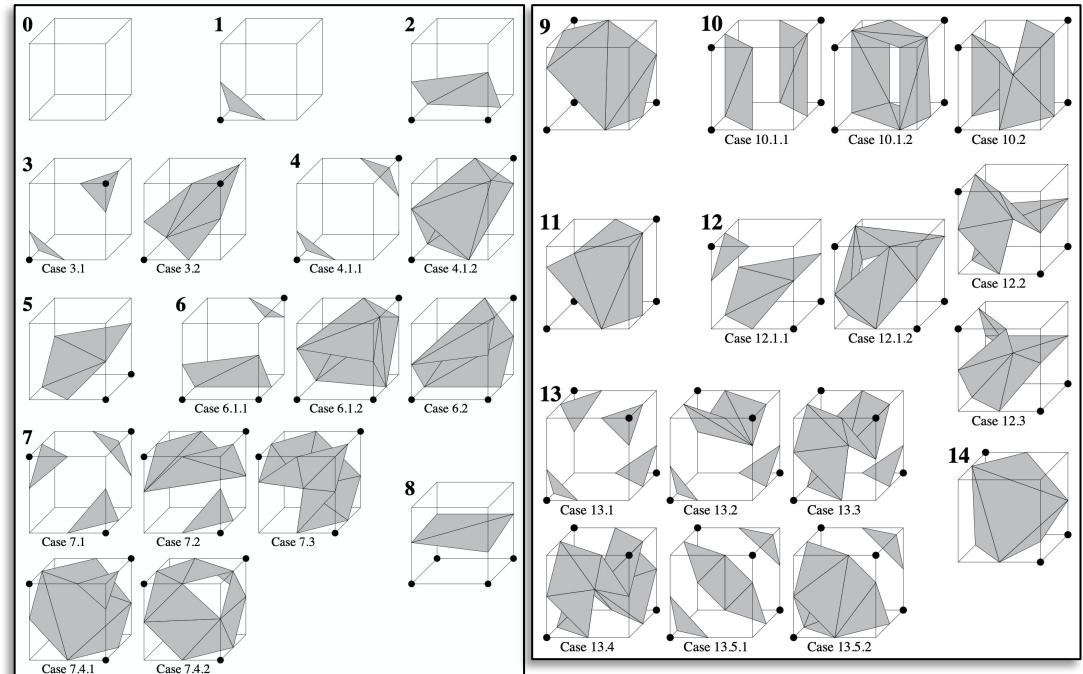


解決法：Bilinear/Trilinear補間に基づいてトポロジを決定

曖昧性を解決するための33種類のパターン  
(正しく実装するのは結構大変・・・)



隣接するセルの間で面が整合しない



The asymptotic decider: resolving the ambiguity in marching cubes [Nielson VIS91]

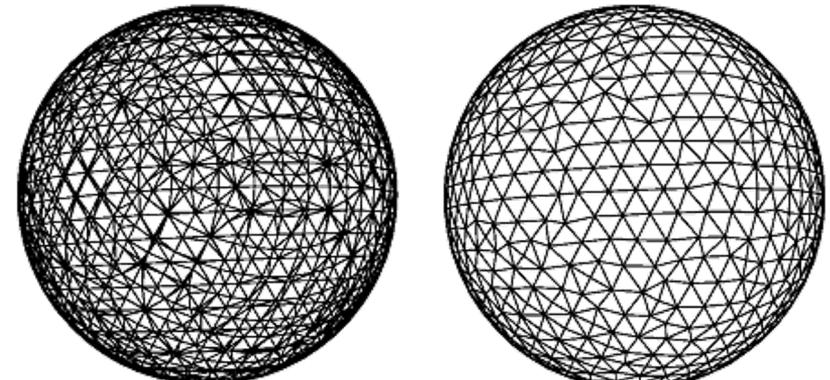
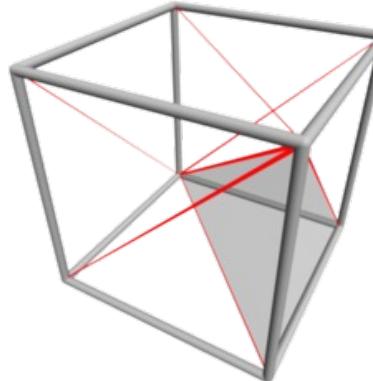
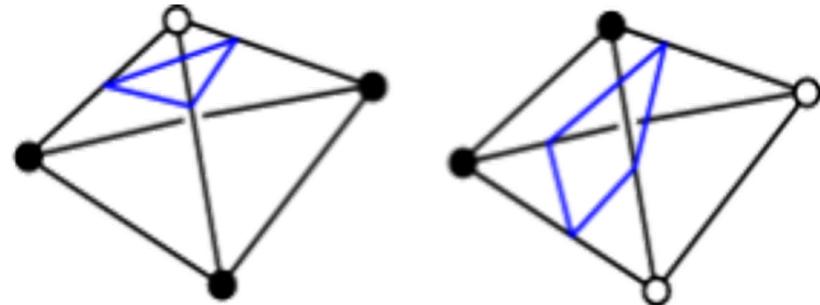
Marching cubes 33: Construction of topologically correct isosurfaces [Chernyaev Tech.Rep. 95]

Topology Verification for Isosurface Extraction [Etiene TVCG12]

A Fast and Memory Saving Marching Cubes 33 Implementation with the Correct Interior Test [Vega JCGT19]

# Marching Tetrahedra

- 立方体の代わりに四面体を使う
  - パターンが少なく、曖昧性が無い ☺  
→ 実装が簡単
  - MCと比べて、三角形の数が多め ☹
- 各立方体セルを、6個の四面体に分割
  - (隣接セル間で分割の向きを合わせることに注意)
- きれいな三角形メッシュを取り出す工夫

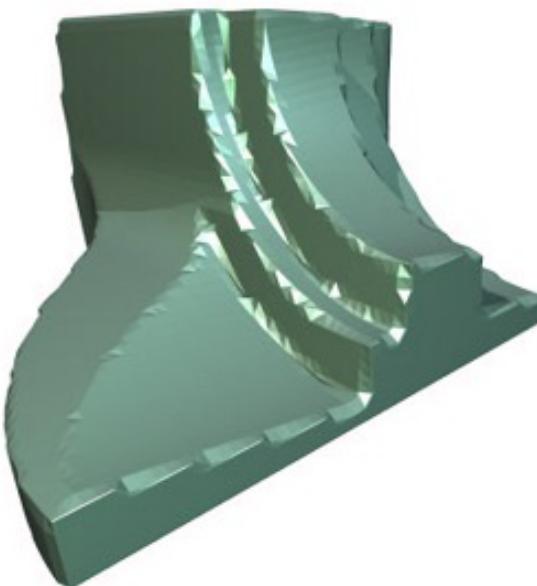


<http://paulbourke.net/geometry/polygonise/>

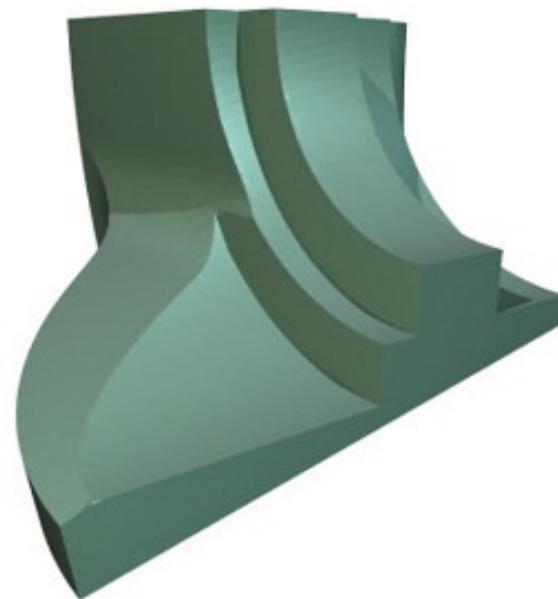
Regularised marching tetrahedra: improved iso-surface extraction [Teece C&G99]

# シャープなエッジを保持した等値面抽出

格子サイズ：65×65×65

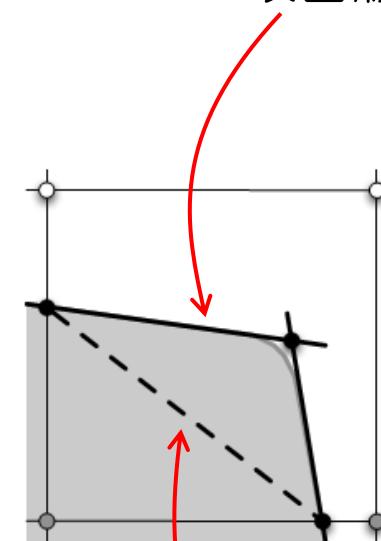


Marching Cubes

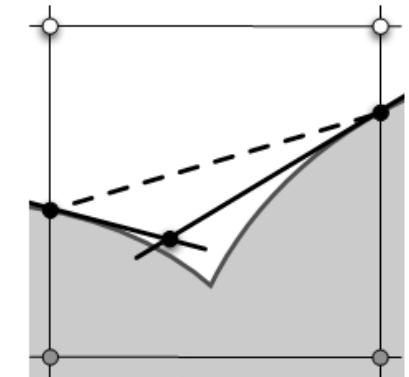


改善版

改善版 (陰関数の勾配も考慮)



改善版 (陰関数の勾配も考慮)



Marching Cubes (陰関数の値のみ考慮)

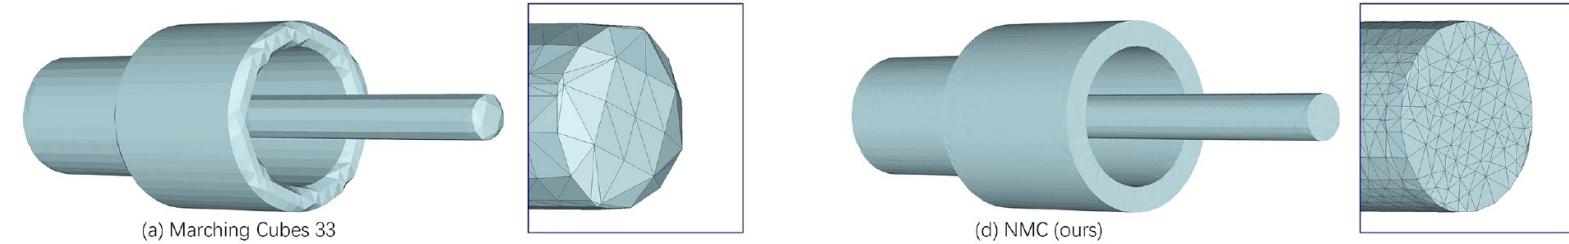
Feature Sensitive Surface Extraction from Volume Data [Kobbelt SIGGRAPH01]

Dual Contouring of Hermite Data [Ju SIGGRAPH02]

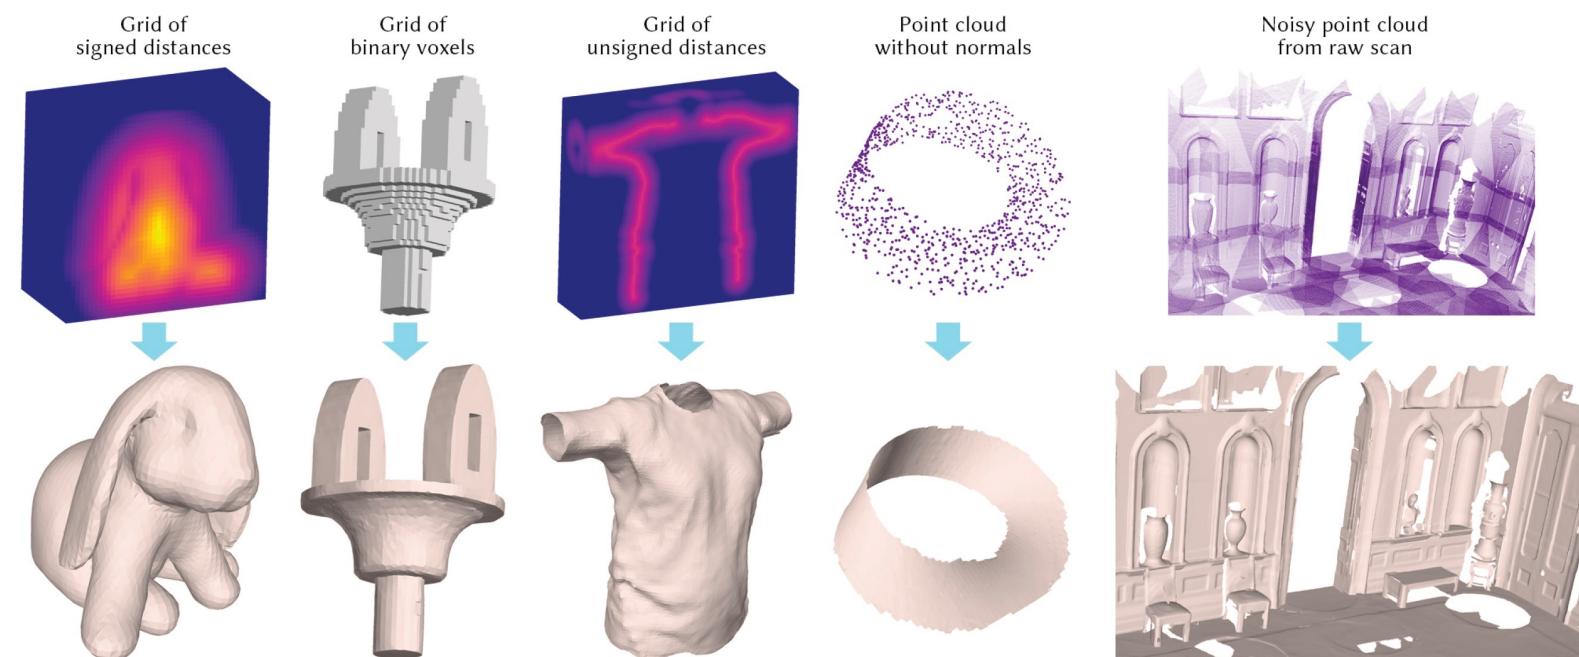
<http://www.graphics.rwth-aachen.de/IsoEx/>

# 深層学習を活用した最近の研究

- Neural Marching Cubes
  - SIGGRAPH Asia 2021



- Neural Dual Contouring
  - SIGGRAPH 2022

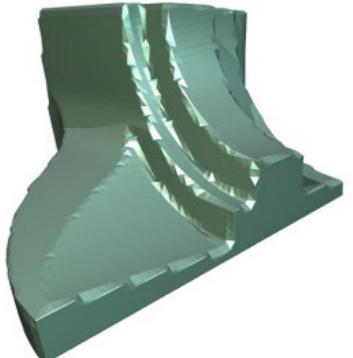


- 両方とも同じ著者

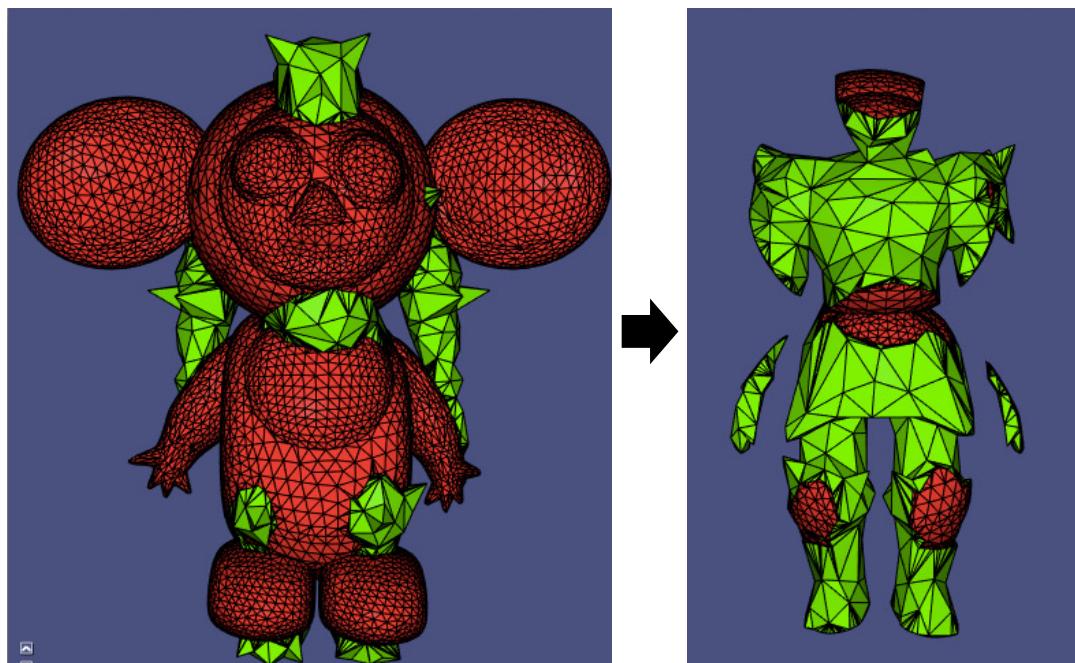
<https://czq142857.github.io/>

# サーフェスマッシュ表現のみに基づく CSG

- ・ボリューム表現 (=Marching Cubesによる等値面抽出)  
→ 近似精度が格子の向きや解像度に依存 ☹



- ・サーフェスマッシュ表現による CSG  
→ 元のメッシュの形状を確実に保持 ☺



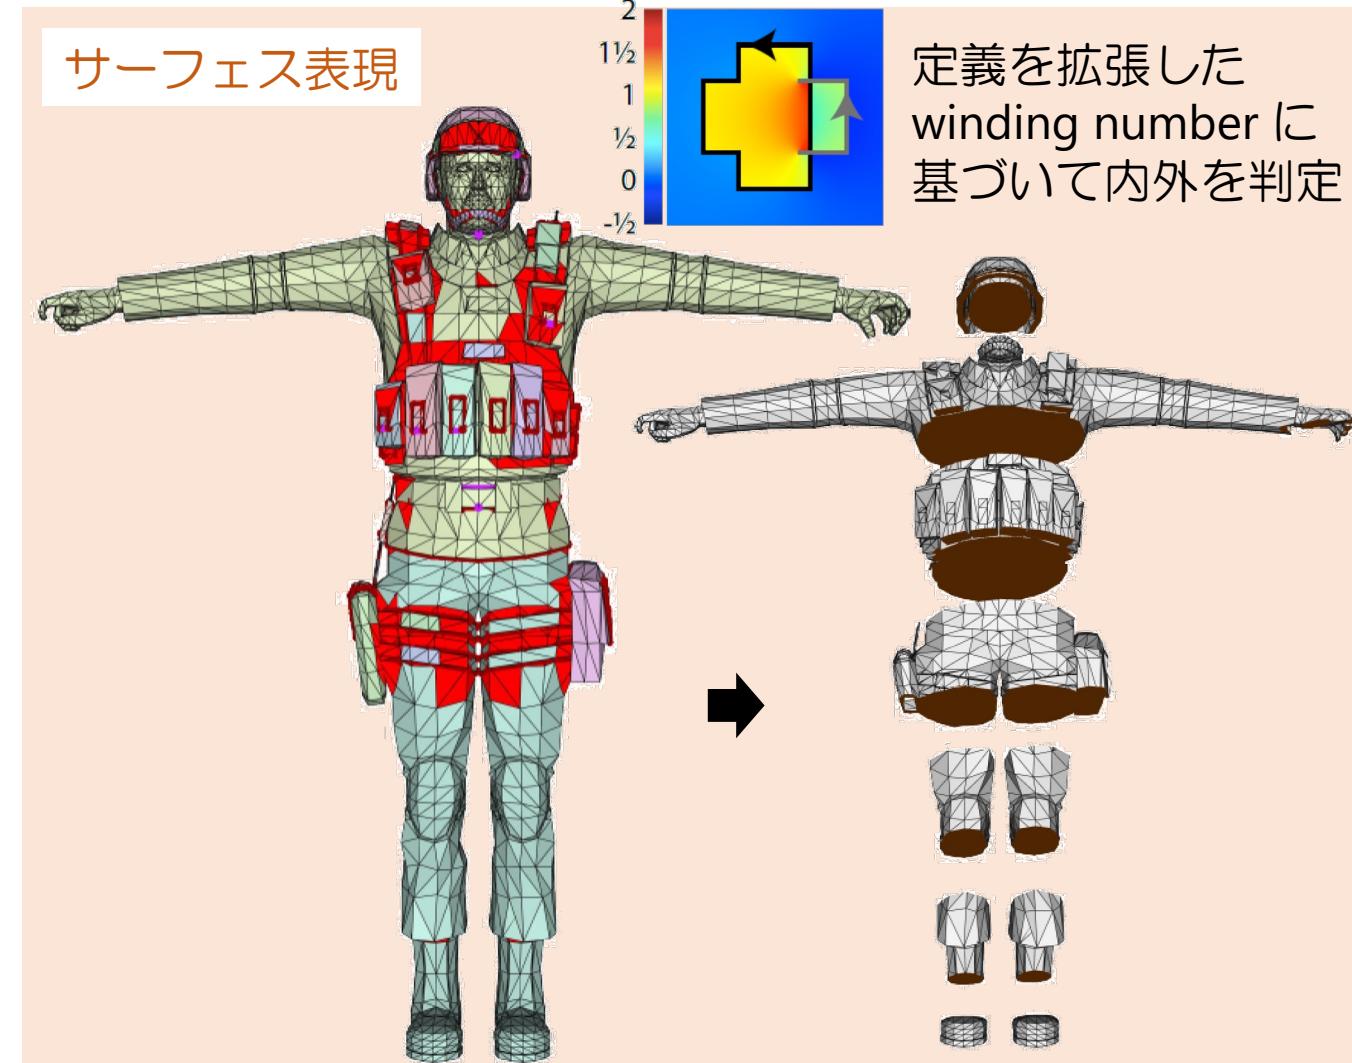
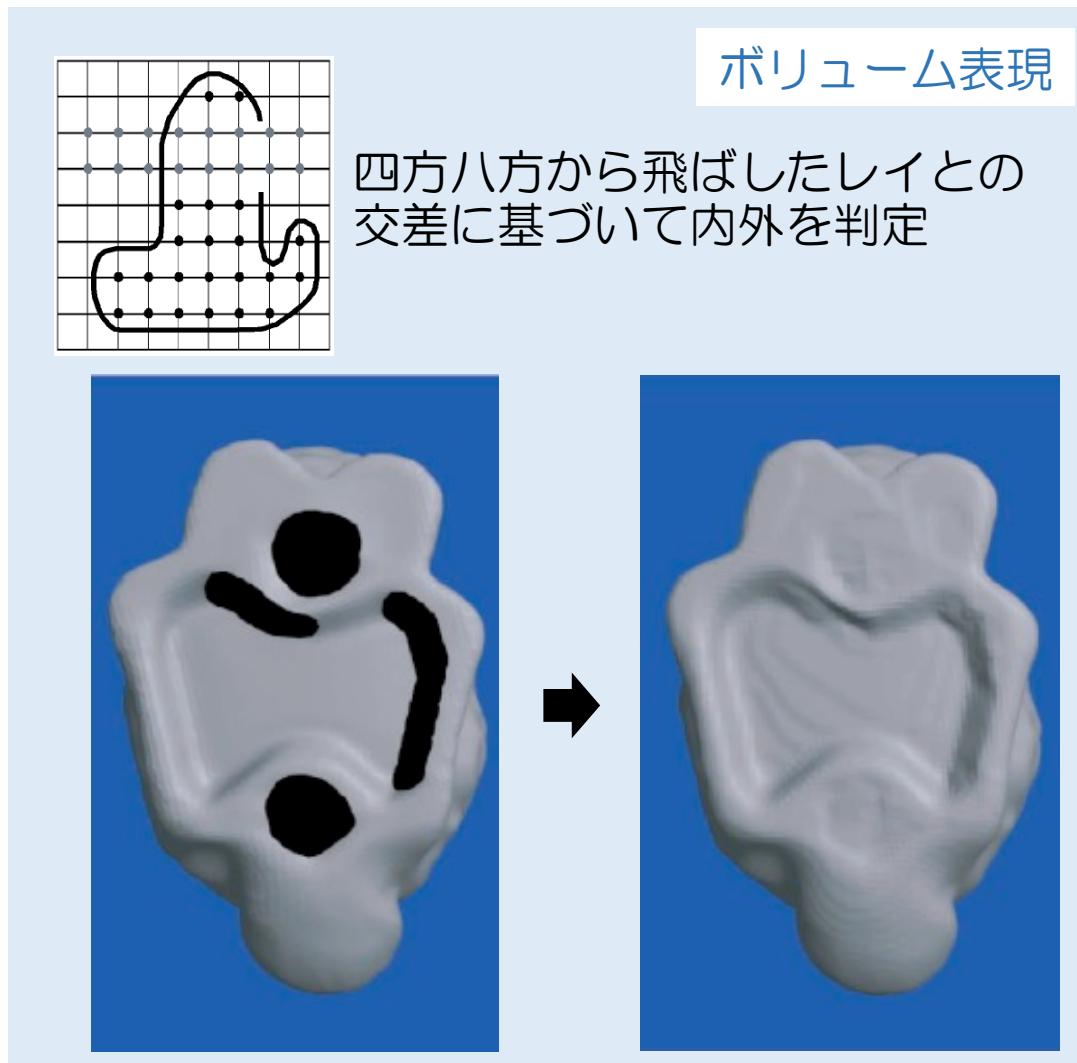
- ・ロバストで効率的な実装が難しい ☹
  - ・浮動小数の丸め誤差
  - ・厳密に同じ位置で重複する複数の三角形



- ・近年著しく進化

Fast, exact, linear booleans [Bernstein SGP09]  
Exact and Robust (Self-)Intersections for Polygonal Meshes [Campen EG10]  
Mesh Arrangements for Solid Geometry [Zhou SIGGRAPH16]  
Exact and Efficient Intersection Resolution for Mesh Arrangements [Guo SIGGRAPHAsia24]  
<https://libigl.github.io/tutorial/#boolean-operations-on-meshes>

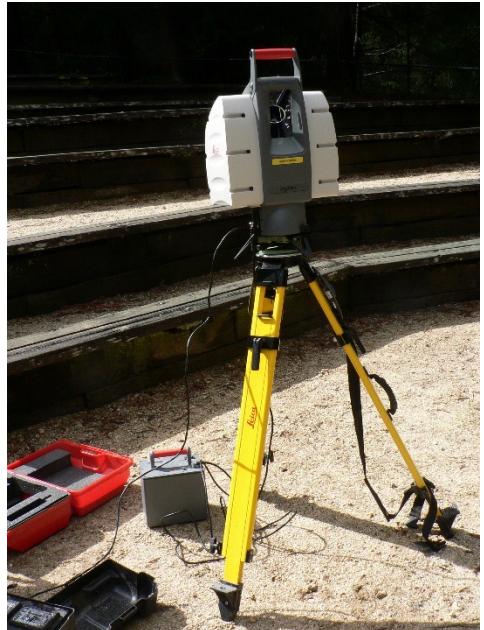
# メッシュの補修 (mesh repair)



Simplification and Repair of Polygonal Models Using Volumetric Techniques [Nooruddin TVCG03]  
Robust Inside-Outside Segmentation using Generalized Winding Numbers [Jacobson SIGGRAPH13]

# 点群からのサーフェス再構成

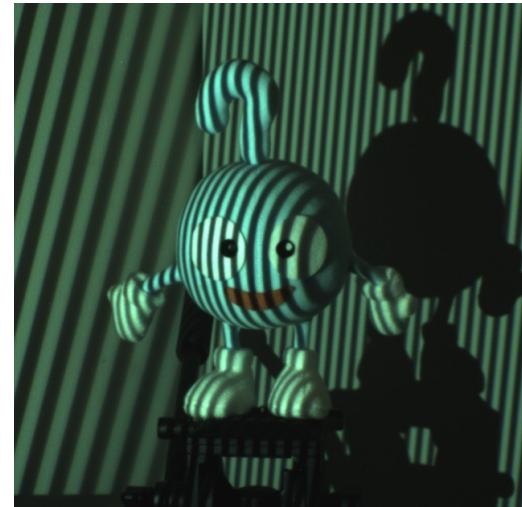
# 3D 形状の計測



Range Scanner  
(LIDAR)

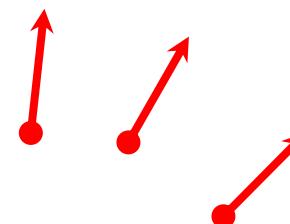


Depth Camera



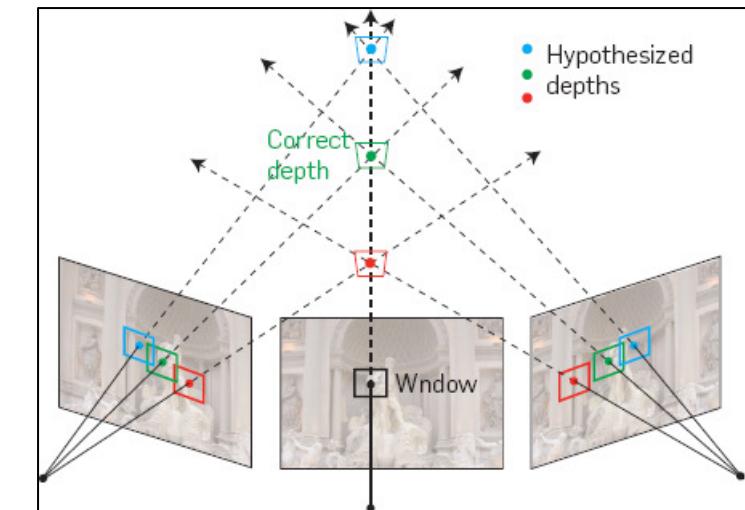
Structured Light

- 得られるデータ：点群
  - 3D座標
  - 法線（面の向き）



- 法線が得られない場合 → 法線の推定
- ノイズが多すぎる場合 → ノイズの除去

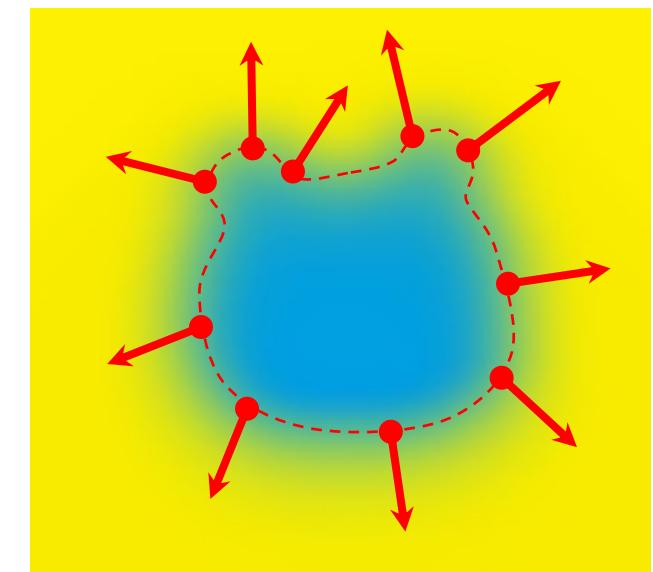
} 今回は取り上げない



Multi-View Stereo

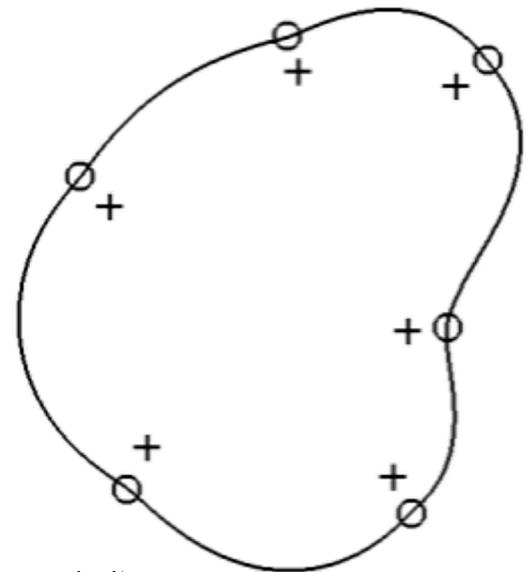
# 点群からのサーフェス形状再構成

- 入力：N 個の点群データ
  - 座標  $\mathbf{x}_i = (x_i, y_i, z_i)$  と法線  $\mathbf{n}_i = (n_i^x, n_i^y, n_i^z), i \in \{1, \dots, N\}$
- 出力：関数  $f(\mathbf{x})$  で、値と勾配の制約を満たすもの
  - $f(\mathbf{x}_i) = f_i$
  - $\nabla f(\mathbf{x}_i) = \mathbf{n}_i$
  - 等値面  $f(\mathbf{x}) = 0$  が出力サーフェス形状
- “Scattered Data Interpolation” と呼ばれる問題
  - **Moving Least Squares**
  - **Radial Basis Function**

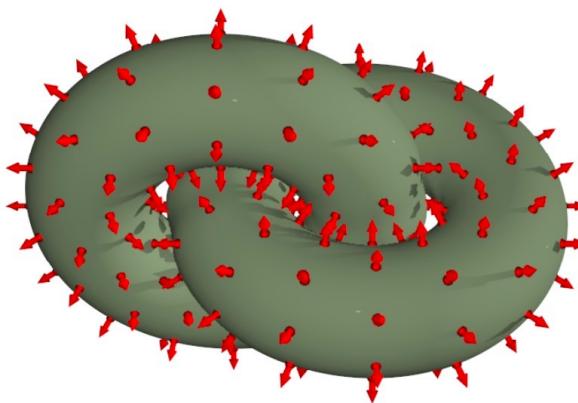


# 勾配を制約する二通りの方法

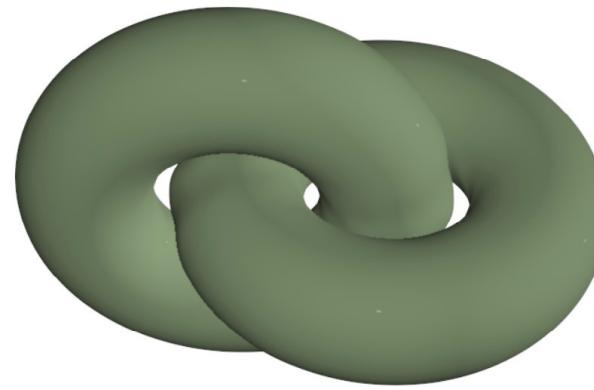
- 法線方向にオフセットした位置に値の制約を追加
  - 簡単



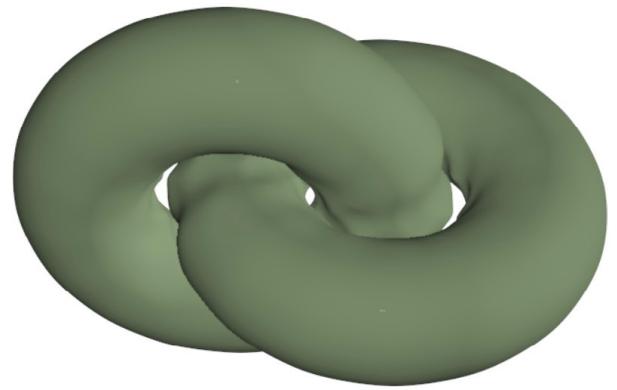
- 数学表現そのものに勾配制約を取り入れる(エルミート補間)
  - 高品質



値と勾配の制約



エルミート補間



オフセット法

# Moving Least Squares による補間 (移動最小二乗)

# 出発点：Least SQuares (最小二乗)

- 求めたい関数が線形だと仮定する： $f(\mathbf{x}) = ax + by + cz + d$ 
  - $a, b, c, d$  が未知係数
- データ点における値の制約

$$\mathbf{x} := (x, y, z)$$

$$f(\mathbf{x}_1) = ax_1 + by_1 + cz_1 + d = f_1$$

$$f(\mathbf{x}_2) = ax_2 + by_2 + cz_2 + d = f_2$$

 $\vdots$  $\vdots$  $\vdots$ 

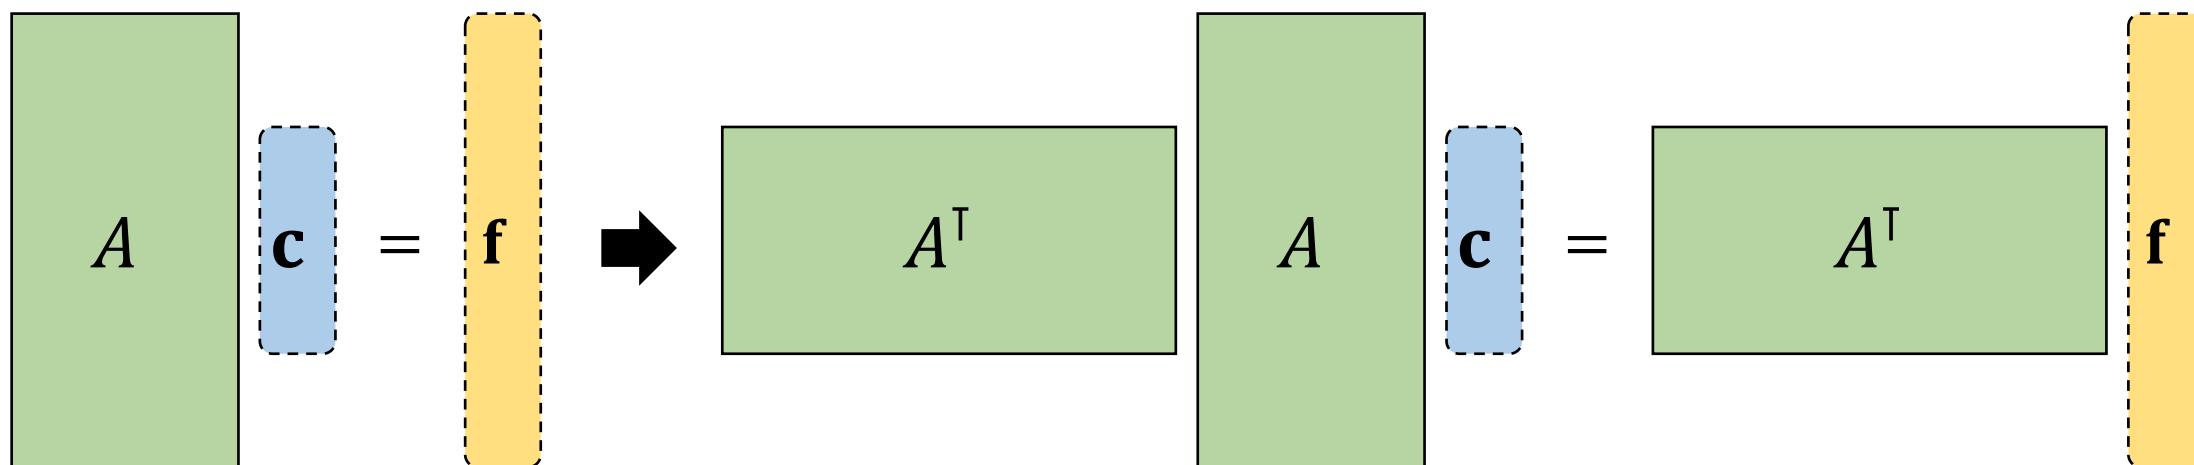
$$f(\mathbf{x}_N) = ax_N + by_N + cz_N + d = f_N$$

- (勾配制約は今は考えない)

$$\begin{bmatrix} x_1 & y_1 & z_1 & 1 \\ x_2 & y_2 & z_2 & 1 \\ \vdots & \vdots & \vdots & \vdots \\ x_N & y_N & z_N & 1 \end{bmatrix} \begin{bmatrix} a \\ b \\ \mathbf{c} \\ d \end{bmatrix} = \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_N \end{bmatrix}$$

# Overconstrained System

- #未知数 < #制約 (i.e. 縦長の行列) → 全ての制約を同時に満たせない



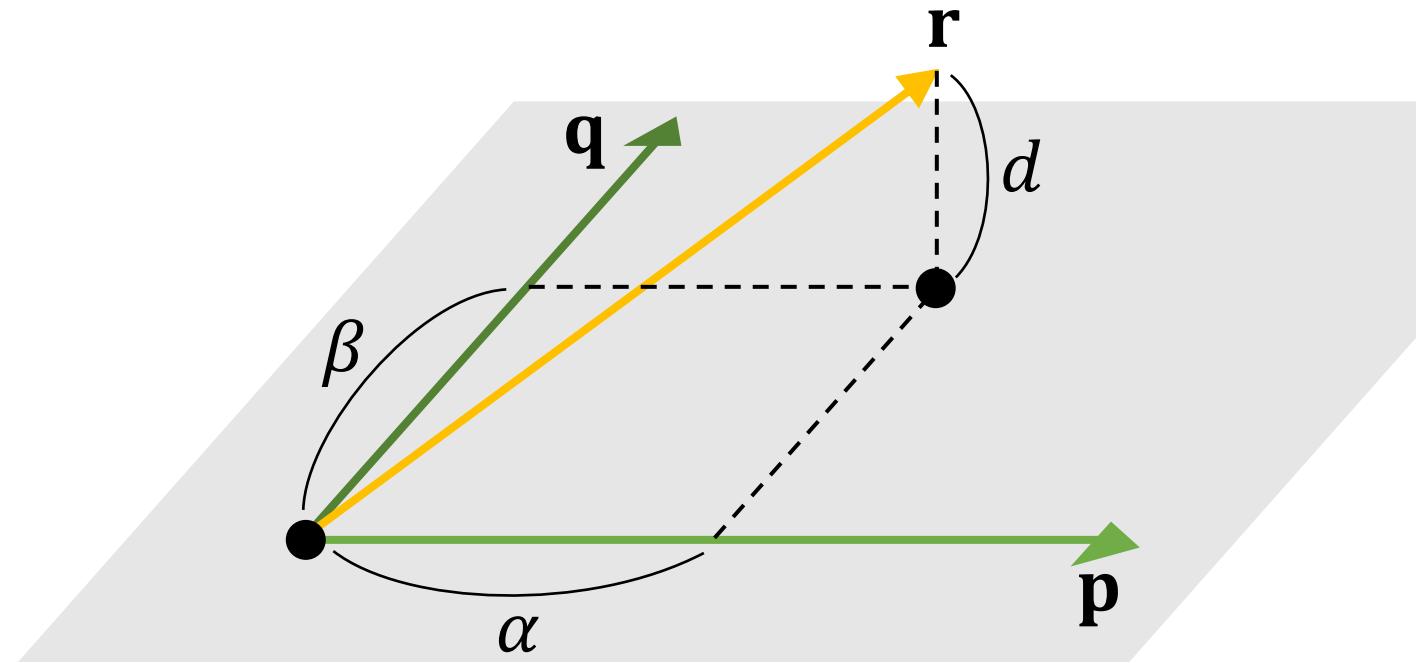
- fitting の誤差を最小化 :

$$\|A \mathbf{c} - \mathbf{f}\|^2 = \sum_{i=1}^N \|f(\mathbf{x}_i) - f_i\|^2$$

$$\mathbf{c} = (A^\top A)^{-1} A^\top \mathbf{f}$$

# LSQ の幾何的な解釈

$$\begin{bmatrix} p_x & q_x \\ p_y & q_y \\ p_z & q_z \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} r_x \\ r_y \\ r_z \end{bmatrix}$$



- $\mathbf{p}$  と  $\mathbf{q}$  が張る空間中で  $\mathbf{r}$  に最も近い点を求める (投影する) ことに相当
  - fitting 誤差は投影距離に相当 :

$$d^2 = \|\alpha\mathbf{p} + \beta\mathbf{q} - \mathbf{r}\|^2$$

# Weighted Least Squares (重み付き最小二乗)

- 各データ点ごとの誤差に、重み  $w_i$  をつける
  - 重要度、確信度
- 以下の誤差を最小化：

$$\sum_{i=1}^N \|w_i(f(\mathbf{x}_i) - f_i)\|^2$$

$$\begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_N \end{bmatrix} \begin{bmatrix} x_1 & y_1 & z_1 & 1 \\ x_2 & y_2 & z_2 & 1 \\ \vdots & & & \\ x_N & y_N & z_N & 1 \end{bmatrix} \begin{bmatrix} a \\ b \\ \mathbf{c} \\ d \end{bmatrix} = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_N \end{bmatrix} \begin{bmatrix} f_1 \\ f_2 \\ \mathbf{f} \\ \vdots \\ f_N \end{bmatrix}$$

# Weighted Least Squares (重み付き最小二乗)

$$\begin{matrix} W \\ A \end{matrix} \quad \boxed{\mathbf{c}} = \begin{matrix} W \\ A \end{matrix} \quad \boxed{\mathbf{f}}$$

$$\Rightarrow \boxed{\mathbf{c}} = \begin{matrix} (A^\top W^2 A)^{-1} \\ A^\top W^2 \end{matrix} \quad \boxed{\mathbf{f}}$$

# Moving Least Squares (移動最小二乗)

- 重み  $w_i$  が、評価位置  $\mathbf{x}$  に依存：

$$w_i(\mathbf{x}) = w(\|\mathbf{x} - \mathbf{x}_i\|)$$

- よく使われる関数 (Kernel) :

- $w(r) = e^{-r^2/\sigma^2}$

- $w(r) = \frac{1}{r^2 + \epsilon^2}$

評価位置に近いほど  
大きな重み

- 重み行列  $W$  が  $\mathbf{x}$  に依存

→ 系数  $a, b, c, d$  が  $\mathbf{x}$  に依存

$$f(\mathbf{x}) = [x \ y \ z \ 1]$$

- 評価点ごとに  
方程式を解き直す

$$\begin{matrix} a(\mathbf{x}) \\ b(\mathbf{x}) \\ (A^\top W(\mathbf{x})^2 A)^{-1} \\ c(\mathbf{x}) \\ d(\mathbf{x}) \end{matrix} \quad A^\top W(\mathbf{x})^2 \quad \mathbf{f}$$

# 法線制約の導入

- 各データ点が表す 1 次式を考える：

$$g_i(\mathbf{x}) = f_i + (\mathbf{x} - \mathbf{x}_i)^\top \mathbf{n}_i$$

- 各  $g_i$  を現在位置で評価したときの誤差を最小化：

$$\sum_{i=1}^N \|w_i(\mathbf{x})(f(\mathbf{x}) - g_i(\mathbf{x}))\|^2$$

$$\begin{bmatrix} w_1(\mathbf{x}) \\ w_2(\mathbf{x}) \\ \ddots \\ w_N(\mathbf{x}) \end{bmatrix} \begin{bmatrix} x & y & z & 1 \\ x & y & z & 1 \\ \vdots & \vdots & \vdots & \vdots \\ x & y & z & 1 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \\ d \end{bmatrix} = \begin{bmatrix} w_1(\mathbf{x}) \\ w_2(\mathbf{x}) \\ \ddots \\ w_N(\mathbf{x}) \end{bmatrix} \begin{bmatrix} g_1(\mathbf{x}) \\ g_2(\mathbf{x}) \\ \vdots \\ g_N(\mathbf{x}) \end{bmatrix}$$

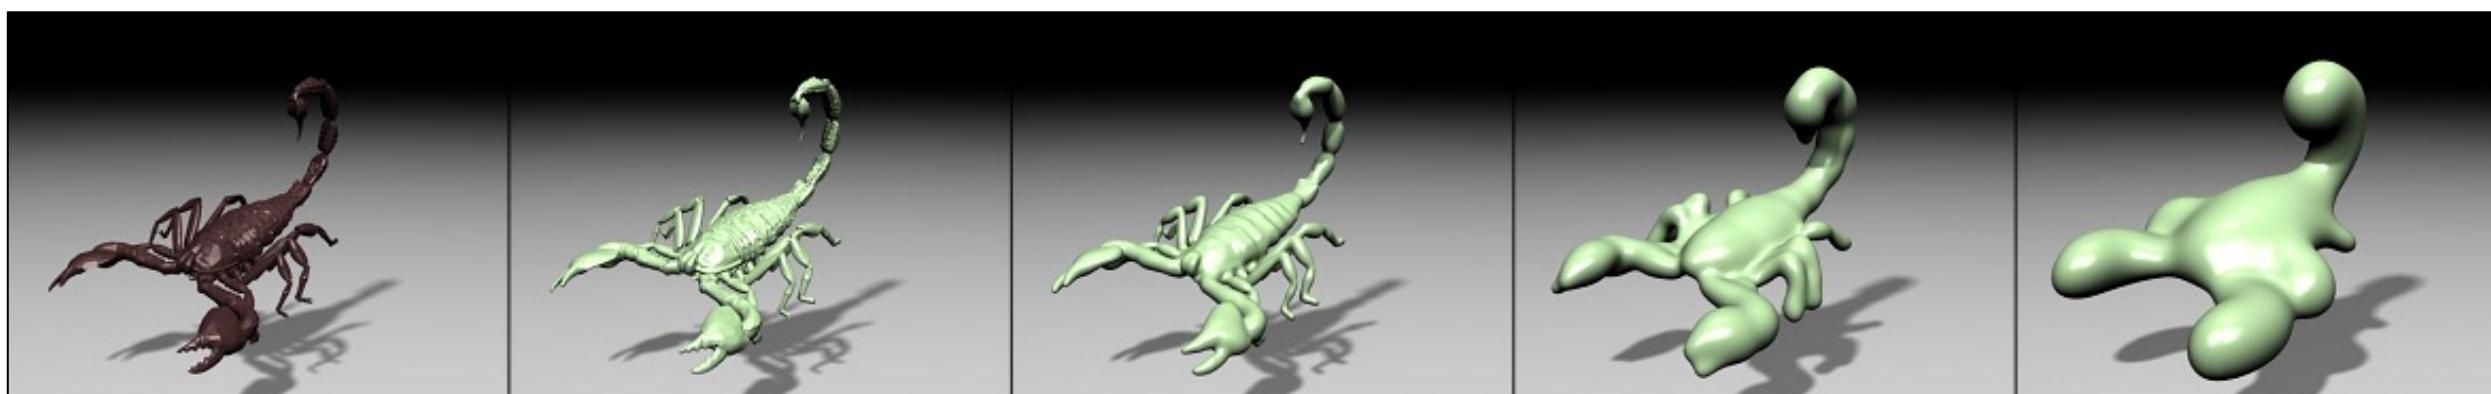
# 法線制約の導入



法線制約を利用



法線方向にオフセットして値を制約



Input : Polygon Soup

Interpolation

Approximation 1

Approximation 2

Approximation 3

# Radial Basis Function による補間 (放射基底関数)

注意：数学的な原理について私自身が理解できていません 😢

# RBFの式

$$f(\mathbf{x}) = \sum_{i=1}^N w_i \phi(\mathbf{x} - \mathbf{x}_i) + ax + by + cz + d$$

- $\phi(\cdot)$  は基底関数
  - $\phi(\mathbf{x}) = \|\mathbf{x}\|^3$
- $N + 4$  個の係数を求めるための制約条件
  - $f(\mathbf{x}_i) = f_i \quad (i = 1, 2, \dots, N)$
  - $\sum w_i = \sum x_i w_i = \sum y_i w_i = \sum z_i w_i = 0$
- よく言われているが、理解できていない：
  - 2Dの場合  $\phi(\mathbf{x}) = \|\mathbf{x}\|^2 \log \|\mathbf{x}\|$  の方が良い (?)
  - Biharmonicエネルギー  $\int_{\mathbb{R}^d} \|\nabla^2 f(\mathbf{x})\|^2 d\mathbf{x}$  を最小化する (?)
    - $\nabla^2 f(x, y) := (f_{xx}, f_{xy}, f_{yx}, f_{yy})$
- 基底関数として他の選択肢もあり得る (e.g.  $e^{-\|\mathbf{x}\|^2/\sigma^2}$ )
  - ただし  $\|\mathbf{x}\|^2$  は行列が特異になるのでダメ!

$$\begin{array}{c} \phi_{i,j} = \phi(\mathbf{x}_i - \mathbf{x}_j) \\ \\ \Phi \begin{matrix} & & & \vdots & \mathbf{P} \\ & \ddots & & & \vdots \\ & & & \vdots & \\ & & & & \end{matrix} \\ \\ \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_N \\ a \\ b \\ c \\ d \end{bmatrix} = \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_N \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \end{array}$$

$$\begin{bmatrix} \phi_{1,1} & \phi_{1,2} & \cdots & \phi_{1,N} & x_1 & y_1 & z_1 & 1 \\ \phi_{2,1} & \phi_{2,2} & \cdots & \phi_{2,N} & x_2 & y_2 & z_2 & 1 \\ & & \ddots & & & & & \\ & & & \phi_{N,1} & \phi_{N,2} & \cdots & \phi_{N,N} & x_N & y_N & z_N & 1 \\ x_1 & x_2 & \cdots & x_N & 0 & 0 & 0 & 0 \\ y_1 & y_2 & \cdots & y_N & 0 & 0 & 0 & 0 \\ z_1 & z_2 & \cdots & z_N & 0 & 0 & 0 & 0 \\ 1 & 1 & \cdots & 1 & 0 & 0 & 0 & 0 \end{bmatrix}$$

[https://en.wikipedia.org/wiki/Polyharmonic\\_spline](https://en.wikipedia.org/wiki/Polyharmonic_spline)  
Scattered Data Approximation (Wendland, 2004)

# 勾配制約の導入

- 基底関数の勾配  $\nabla\phi$  の重み付き和を導入：

$$f(\mathbf{x}) = \sum_{i=1}^N \left\{ \mathbf{w}_i \phi(\mathbf{x} - \mathbf{x}_i) + \mathbf{v}_i^\top \nabla\phi(\mathbf{x} - \mathbf{x}_i) \right\} + a\mathbf{x} + b\mathbf{y} + c\mathbf{z} + d$$

未知数の3Dベクトル

- $f$  の勾配：

$$\nabla f(\mathbf{x}) = \sum_{i=1}^N \left\{ \mathbf{w}_i \nabla\phi(\mathbf{x} - \mathbf{x}_i) + \mathbf{H}_\phi(\mathbf{x} - \mathbf{x}_i) \mathbf{v}_i \right\} + \begin{bmatrix} a \\ b \\ c \end{bmatrix}$$

- 勾配の制約  $\nabla f(\mathbf{x}_i) = \mathbf{n}_i$  を追加

$$\mathbf{H}_\phi(\mathbf{x}) = \begin{pmatrix} \phi_{xx} & \phi_{xy} & \phi_{xz} \\ \phi_{yx} & \phi_{yy} & \phi_{yz} \\ \phi_{zx} & \phi_{zy} & \phi_{zz} \end{pmatrix}$$

Hessian 行列 (関数)

# 勾配制約の導入

- 1番目のデータ点について：

値の制約：

$$f(\mathbf{x}_1) = \mathbf{w}_1 \phi_{1,1} + \mathbf{v}_1^\top \nabla \phi_{1,1} + \mathbf{w}_2 \phi_{1,2} + \mathbf{v}_2^\top \nabla \phi_{1,2} + \cdots + \mathbf{w}_N \phi_{1,N} + \mathbf{v}_N^\top \nabla \phi_{1,N}$$

勾配の制約：

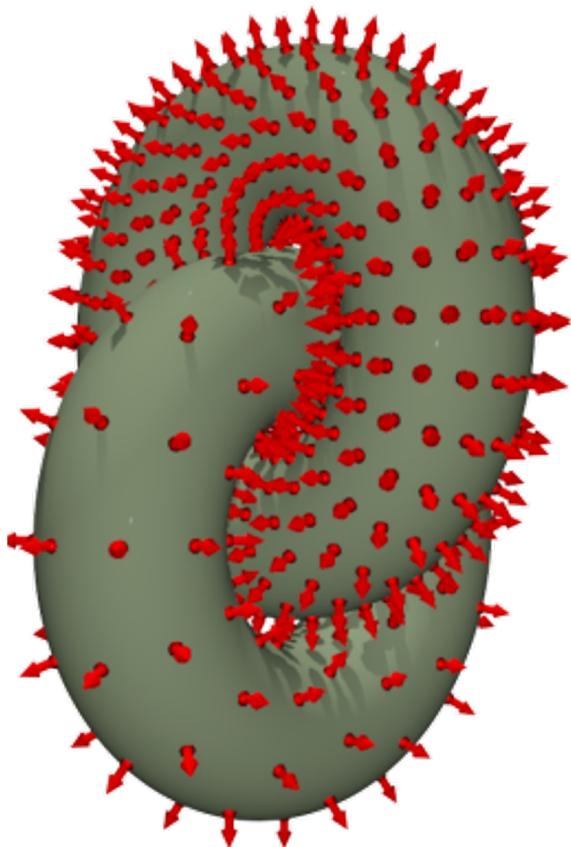
$$\nabla f(\mathbf{x}_1) = \mathbf{w}_1 \nabla \phi_{1,1} + H_\phi^{1,1} \mathbf{v}_1 + \mathbf{w}_2 \nabla \phi_{1,2} + H_\phi^{1,2} \mathbf{v}_2 + \cdots + \mathbf{w}_N \nabla \phi_{1,N} + H_\phi^{1,N} \mathbf{v}_N$$

$$\left[ \begin{array}{c|c} \phi_{1,1} & (\nabla \phi_{1,1})^\top \\ \hline \nabla \phi_{1,1} & \Phi_{1,1} \end{array} \quad \begin{array}{c|c} \phi_{1,2} & (\nabla \phi_{1,2})^\top \\ \hline \nabla \phi_{1,2} & \Phi_{1,2} \end{array} \quad \cdots \quad \begin{array}{c|c} \phi_{1,N} & (\nabla \phi_{1,N})^\top \\ \hline \nabla \phi_{1,N} & \Phi_{1,N} \end{array} \quad \begin{array}{c|c} x_1 & y_1 & z_1 & 1 \\ \hline 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{array} \right]$$

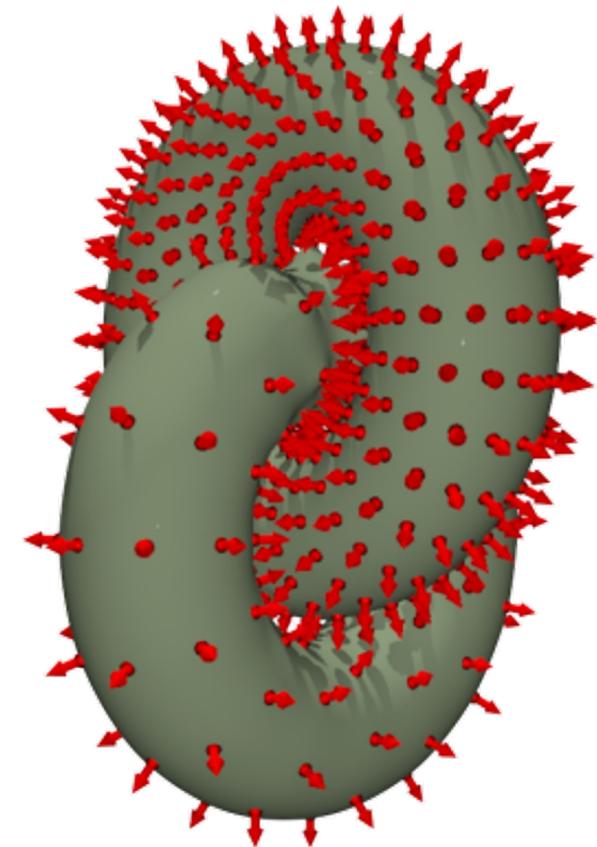
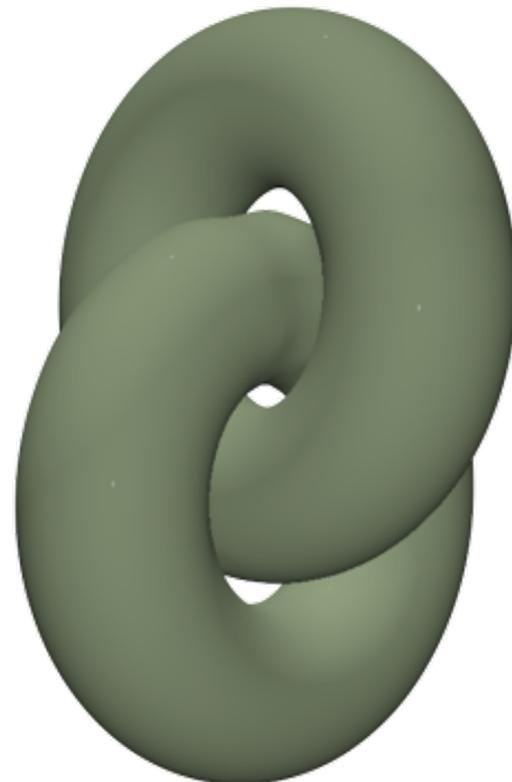
$$\begin{matrix}
 w_1 \\
 \vdots \\
 w_N \\
 \hline
 \mathbf{v}_1 \\
 \vdots \\
 \mathbf{v}_N \\
 \hline
 a \\
 b \\
 c \\
 d
 \end{matrix}
 \leftarrow
 \begin{matrix}
 b y_1 + c z_1 + d = f_1 \\
 \vdots \\
 \mathbf{n}_1
 \end{matrix}
 = 
 \begin{bmatrix}
 f_1 \\
 \mathbf{n}_1
 \end{bmatrix}$$

$$\left[ \begin{array}{cc|cc|cc}
\Phi_{1,1} & \Phi_{1,2} & \cdots & \Phi_{1,N} & P_1 & \\ \hline
\Phi_{2,1} & \Phi_{2,2} & & \Phi_{2,N} & P_2 & \\ \hline
& & \ddots & & \ddots & \\ \hline
\Phi_{N,1} & \Phi_{N,2} & & \Phi_{N,N} & P_N & \\ \hline
P_1^\top & P_2^\top & \cdots & P_N^\top & \begin{matrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{matrix} &
\end{array} \right] = \left[ \begin{array}{c|c}
\begin{matrix} w_1 \\ v_1 \end{matrix} & f_1 \\ \hline
\begin{matrix} w_2 \\ v_2 \end{matrix} & f_2 \\ \hline
\vdots & \vdots \\ \hline
\begin{matrix} w_N \\ v_N \end{matrix} & f_N \\ \hline
\begin{matrix} a \\ b \\ c \\ d \end{matrix} & \begin{matrix} n_1 \\ n_2 \\ \vdots \\ n_N \end{matrix} \\ \hline
0 & 0 \\ 0 & 0 \\ 0 & 0 \\ 0 & 0
\end{array} \right]$$

# 比較



勾配を制約



オフセットして値を制約

# 最近の研究：グローバルな法線推定

- サンプル点  $\{\mathbf{x}_i\}$  における法線  $\{\mathbf{n}_i\}$  が未知のとき、

値の制約  $f(\mathbf{x}_i) = 0$

勾配の制約  $\nabla f(\mathbf{x}_i) = \mathbf{n}_i$

を満たすような関数  $f$  を、RBFを使って一意に定めることができる

→ つまり関数は、未知数の法線  $\{\mathbf{n}_i\}$  に依存して定まる :  $f_{\{\mathbf{n}_i\}}$

→ その滑らかさを測るエネルギーも、 $\{\mathbf{n}_i\}$  に依存して定まる :

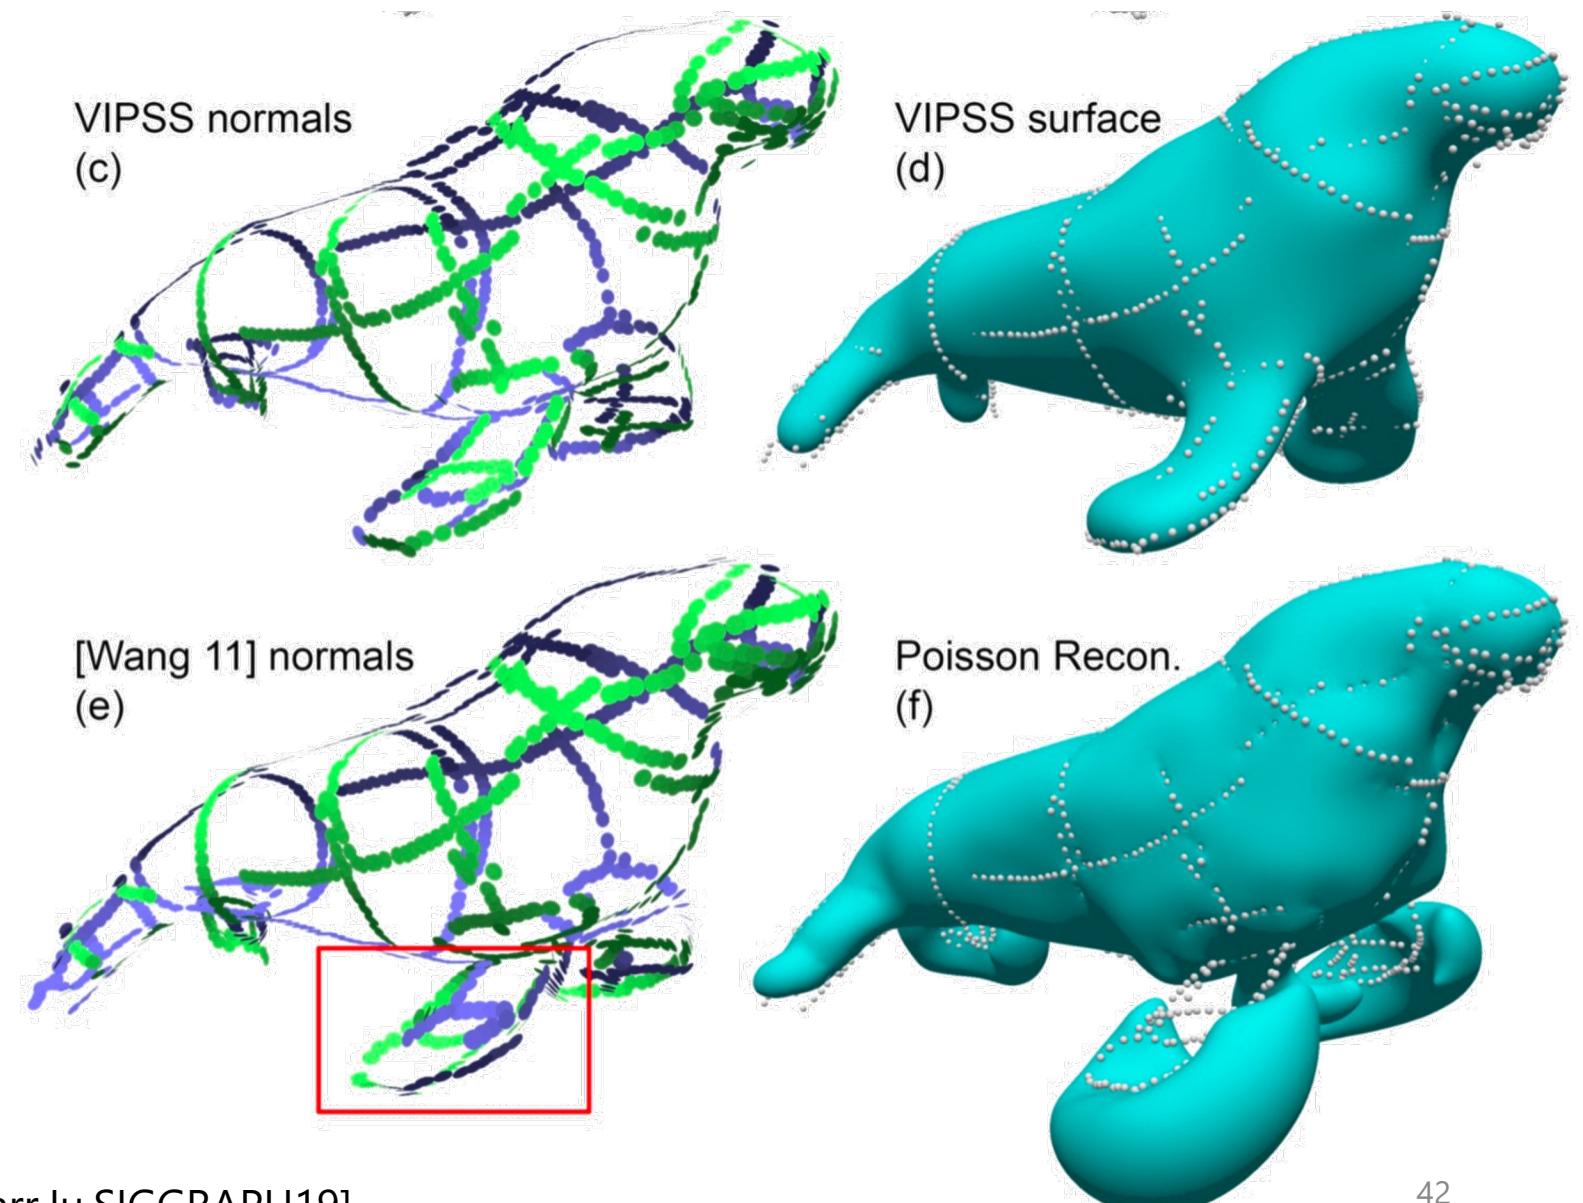
$$\begin{aligned} E_{\{\mathbf{n}_i\}} &:= E[f_{\{\mathbf{n}_i\}}] \\ &= \mathbf{n}^\top H \mathbf{n} \end{aligned} \quad \mathbf{n} = \begin{pmatrix} \vdots \\ \mathbf{n}_i^\top \\ \vdots \end{pmatrix}$$

- 2次制約付き2次計画問題として定式化 :

$$\begin{aligned} &\text{minimize } \mathbf{n}^\top H \mathbf{n} \\ \text{s. t. } &\mathbf{n}_i^\top \mathbf{n}_i = 1 \quad \forall i \end{aligned}$$

行列  $H$  は  $\{\mathbf{x}_i\}$  のみに依存して定まる

# 最近の研究：グローバルな法線推定

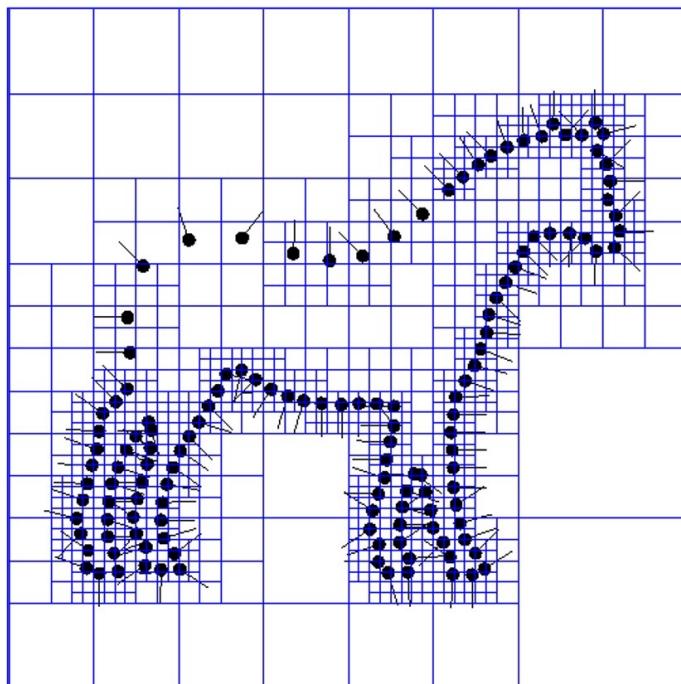


# Poisson Surface Reconstruction

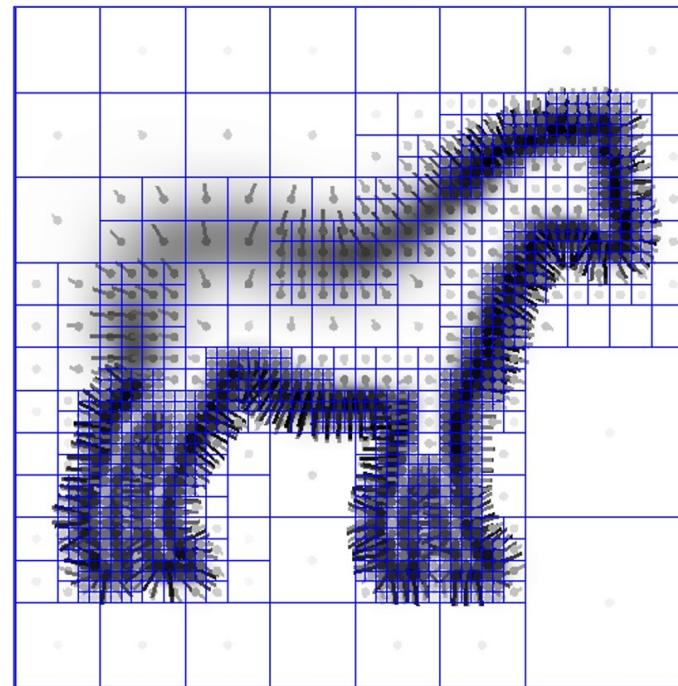
# Poisson Surface Reconstruction (PSR)

Kazhdan et al., Symposium on Geometry Processing 2006

Cited by 3437



点群に基づいて空間を  
適応的に分割する



法線ベクトルを補間して  
ベクトル場  $\vec{V}$  を作る



陰関数  $f$  を以下のように求める：

$$f^* = \arg \min_f \int_B \|\nabla f - \vec{V}\|^2 dx$$

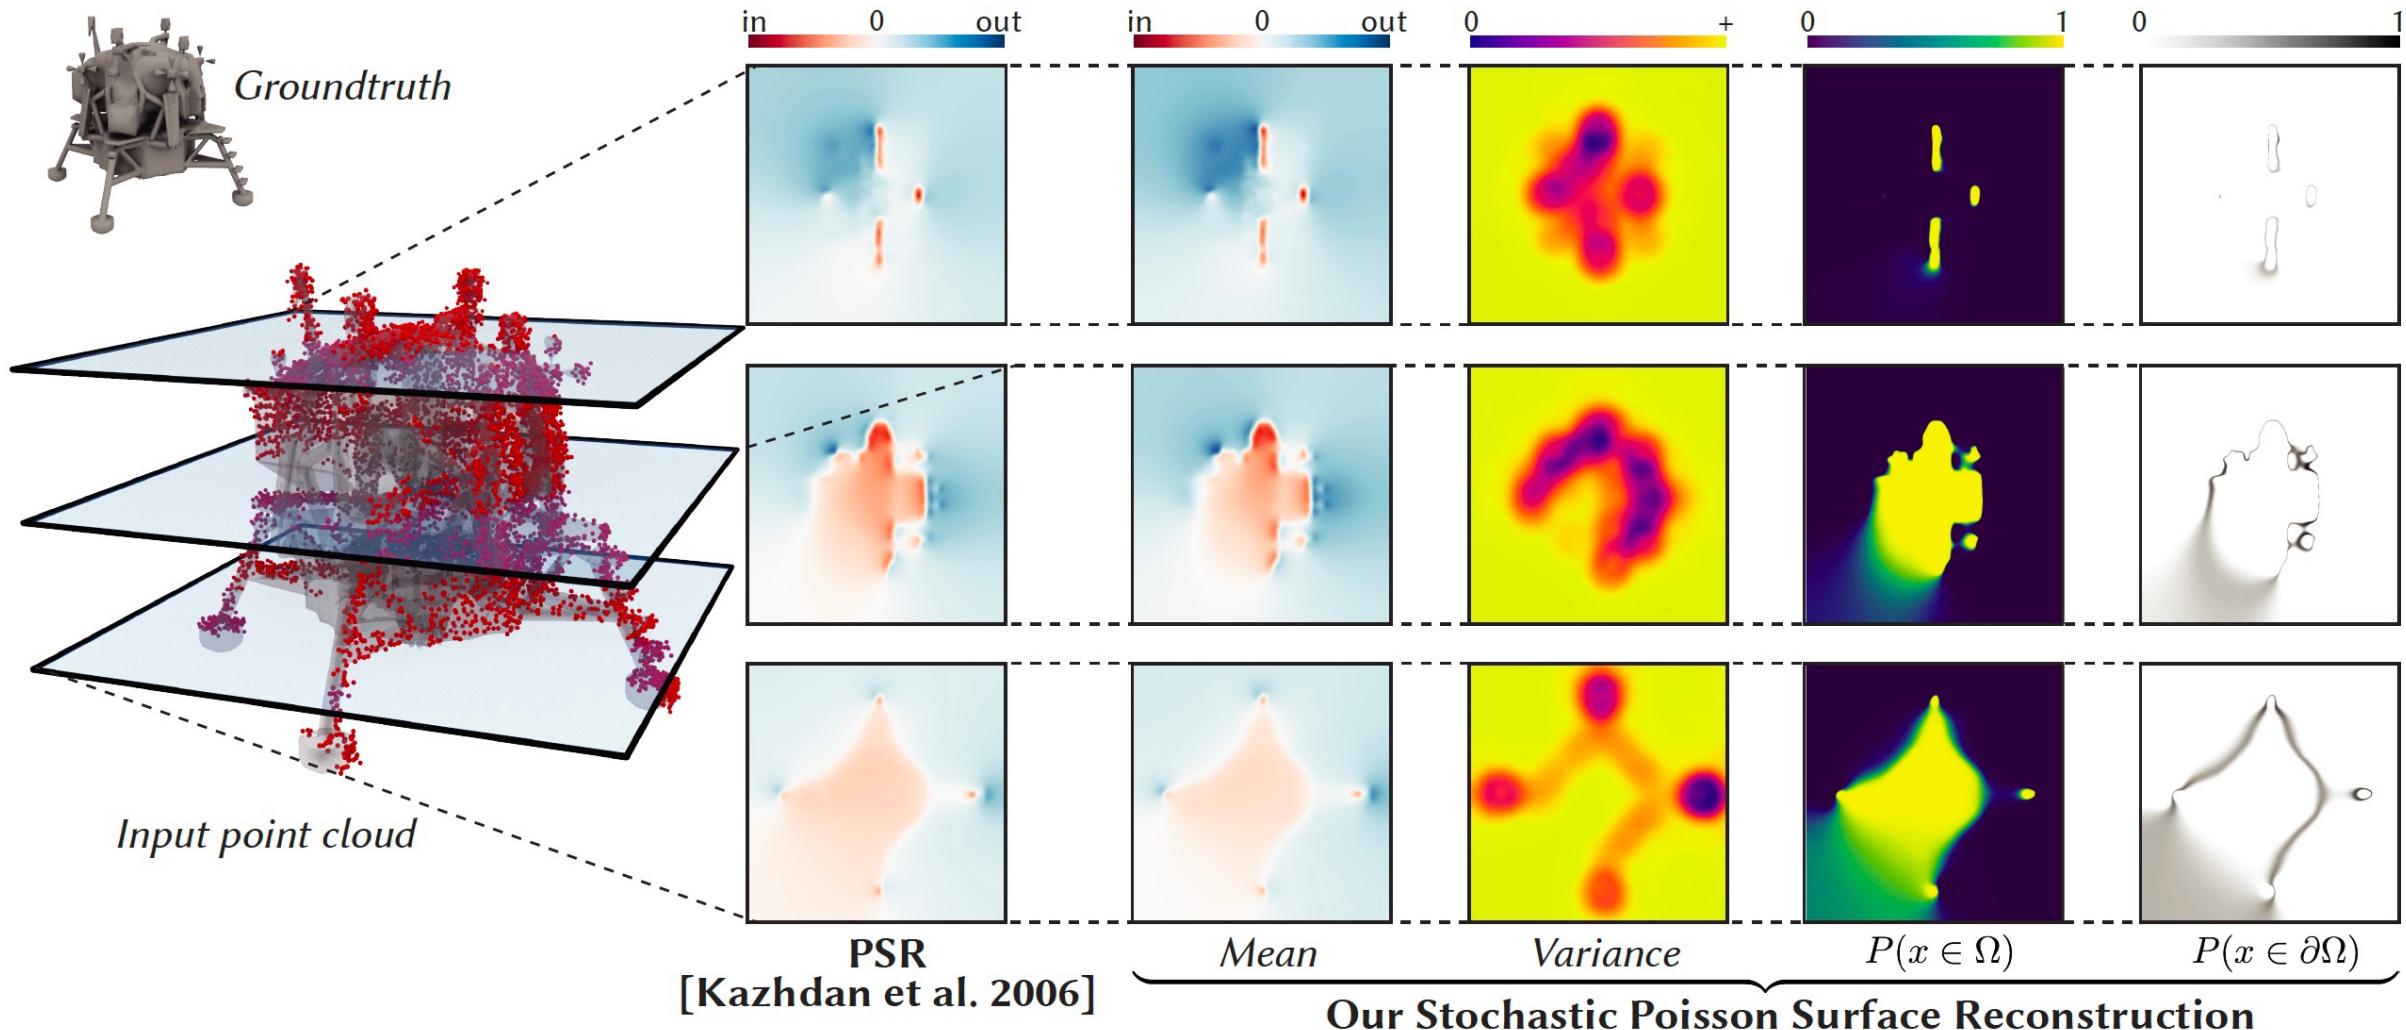


$$\Delta f^* = \nabla \cdot \vec{V}$$

Poisson  
equation

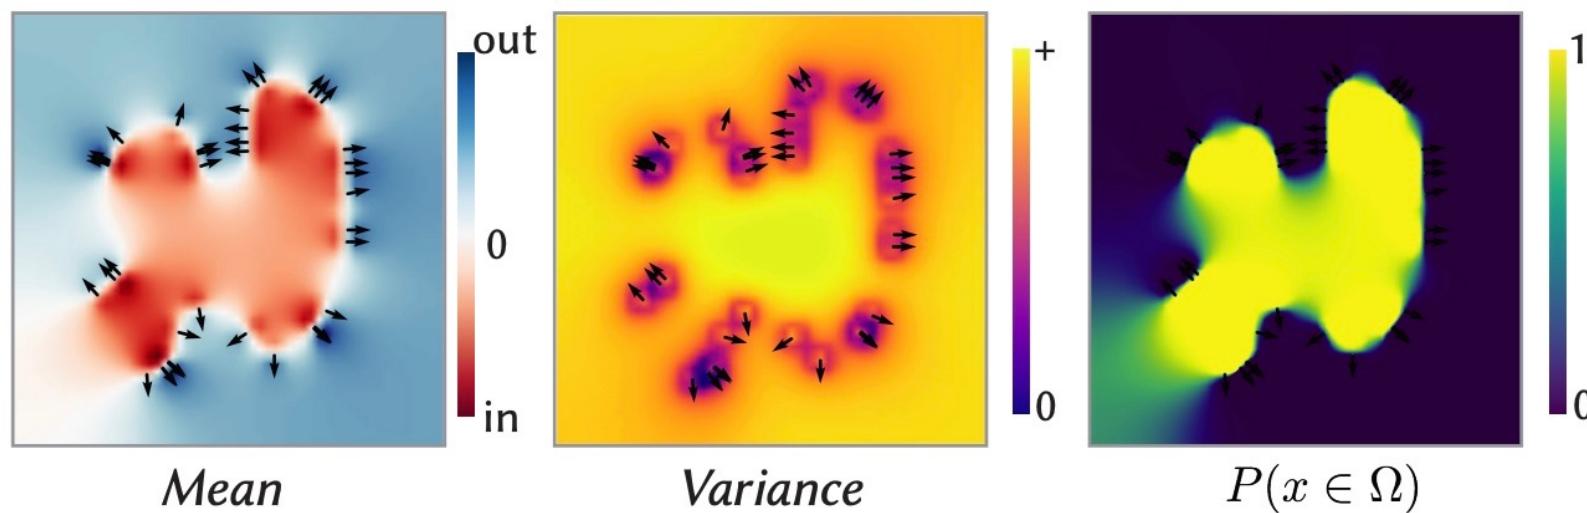
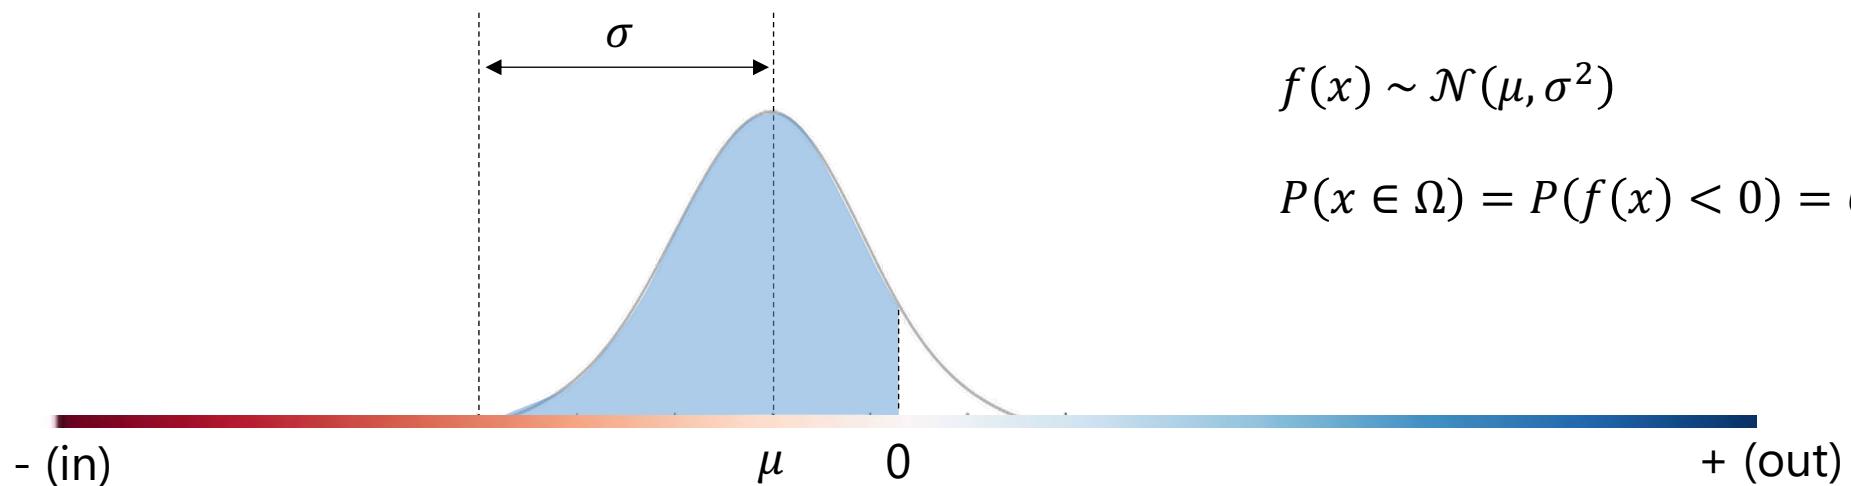
- その後も同じ著者よりいくつか改善版が出ている (2013, 2018, 2020)
- 非常に実用的、業界のデファクトスタンダード
- <https://github.com/mkazhdan/PoissonRecon>

# 最近の研究：Stochastic PSR [SIGGRAPH Asia 2022]



各点において、陰関数の値そのものではなく、値の平均と分散 (ガウス分布) を求める！  
→ 統計量が分かると色々嬉しい

# メリット1：点が物体内部にあるかどうかの確率の計算

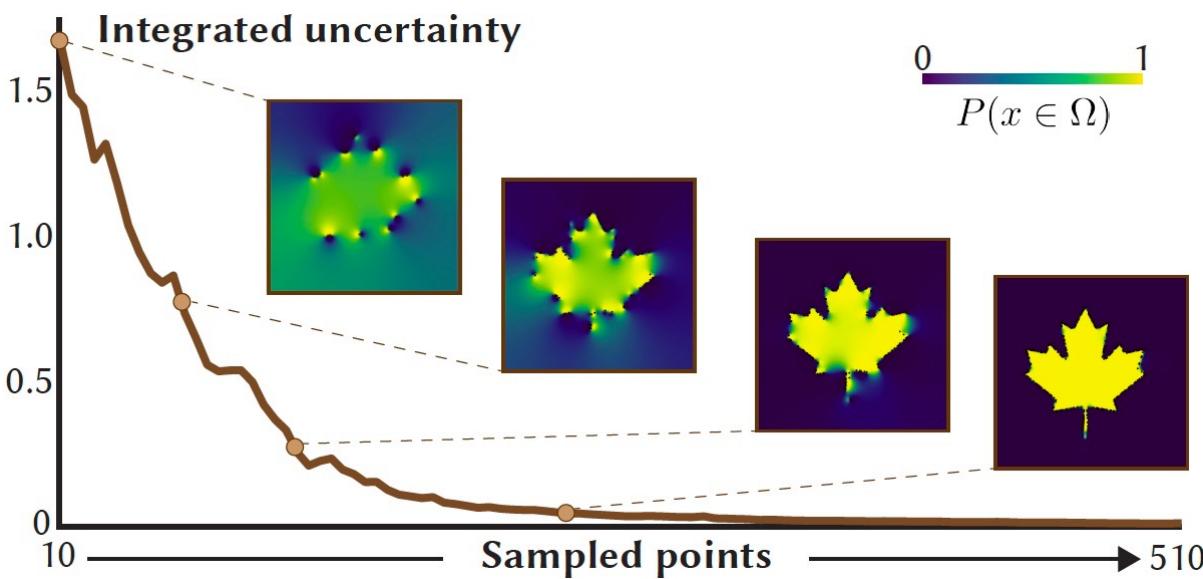


# メリット1：点が物体内部にあるかどうかの確率の計算

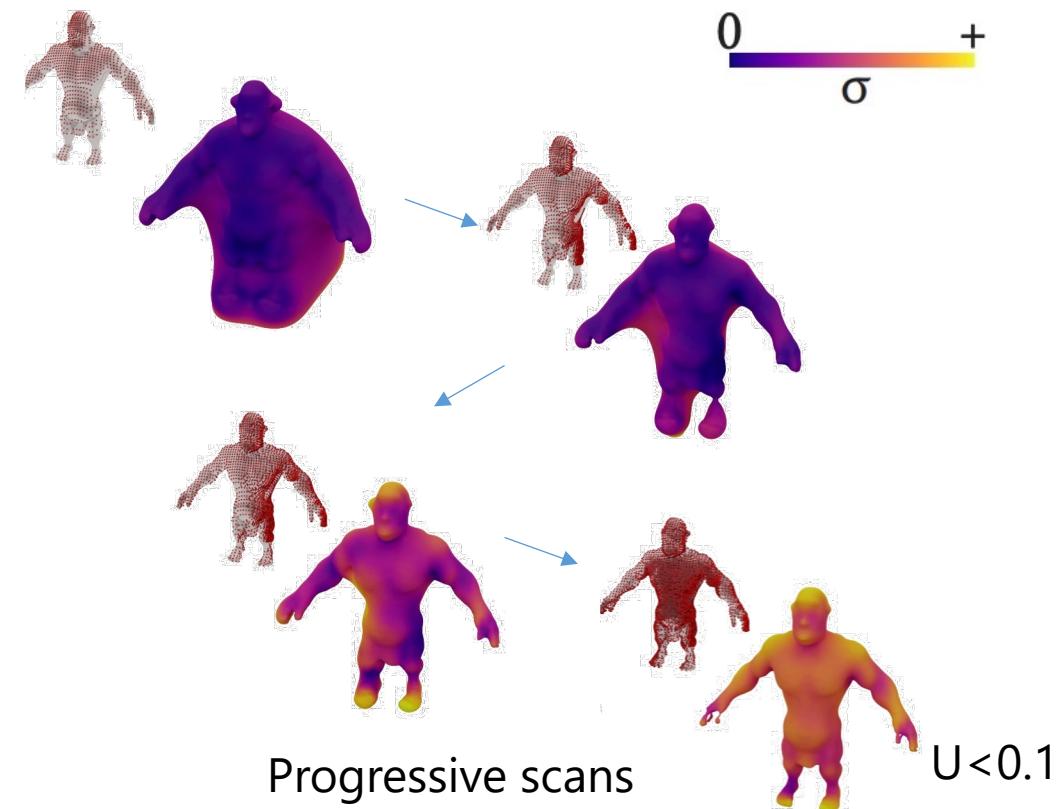
→ 「Total Uncertainty」という量を計算できる

$$U_{SPSR} = \int_B (0.5 - |P(x \in \Omega) - 0.5|) dx$$

→ スキャン追加の必要の有無を判定するのに使える



$$P(x \in \Omega)$$



# メリット2：同時確率を用いた、確率的な衝突判定

$$R_s = \{r_1, \dots, r_s\} \subset R$$

領域Rからランダムにs個のサンプル点を取る



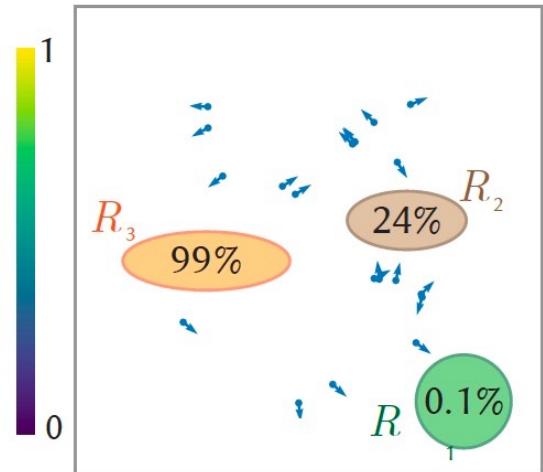
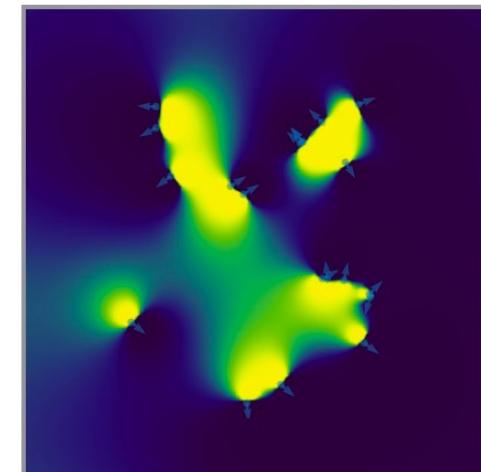
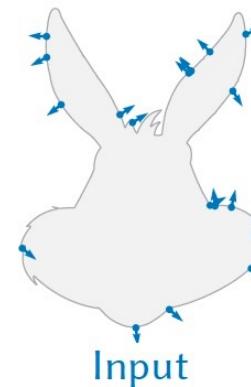
$$\mathbf{f}(r_1, \dots, r_s) | \mathcal{S} \sim \mathcal{N}(\mathbf{W}\mathbf{f}_{SPSR}, \mathbf{W}^\top \mathbf{K}_f \mathbf{W})$$

各サンプル点における確率分布を計算



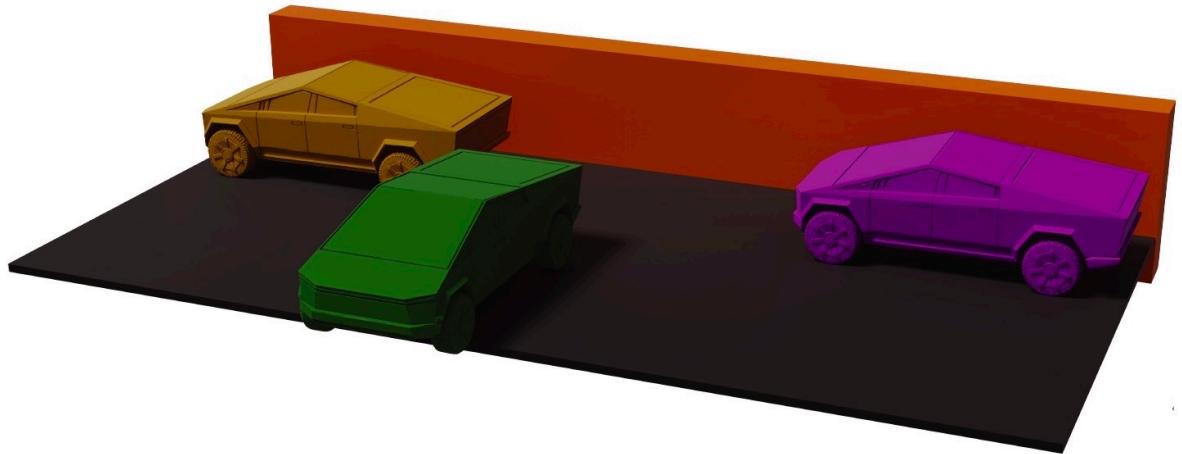
$$p(\mathbf{f}(r_1) > 0, \dots, \mathbf{f}(r_s) > 0))$$

全サンプル点が物体外部である確率を計算

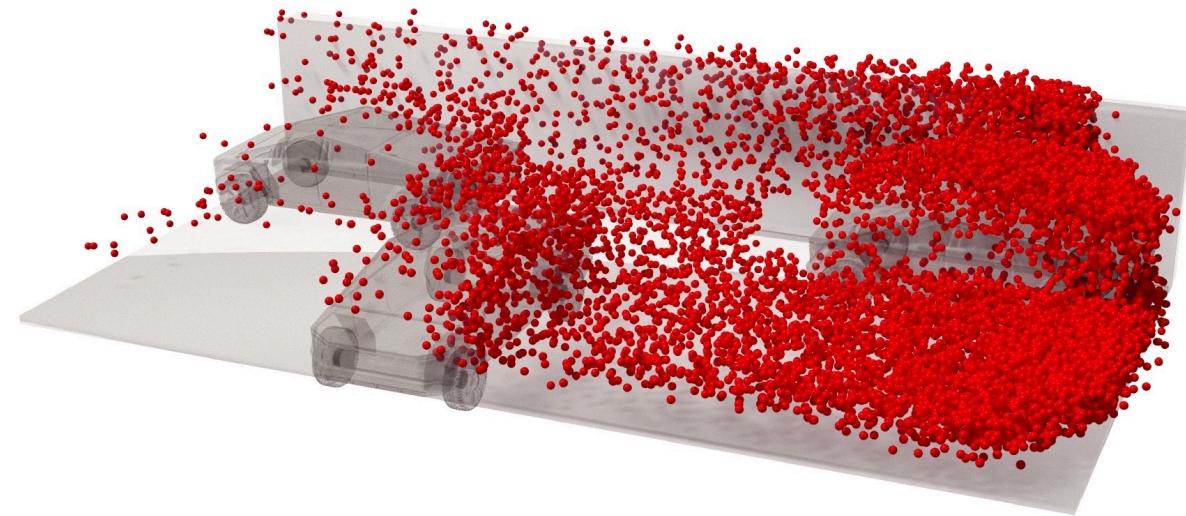


# メリット2：同時確率を用いた、確率的な衝突判定

自動運転のシナリオ

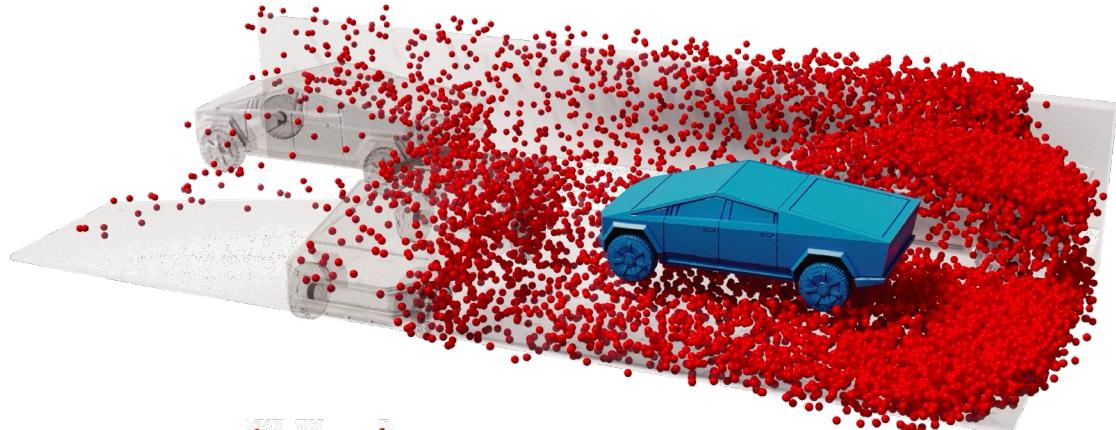


3Dシーン



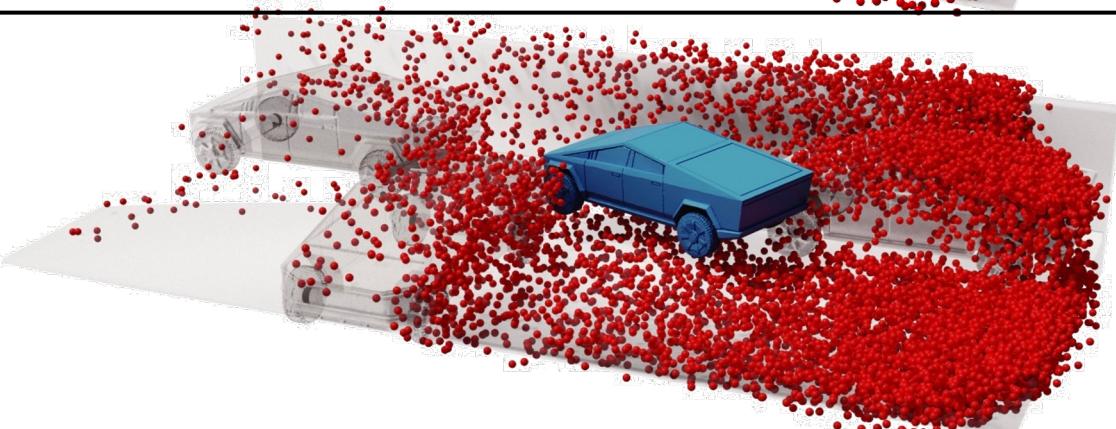
スキャンを模した点群データ

## メリット2：同時確率を用いた、確率的な衝突判定



PSRによる判定

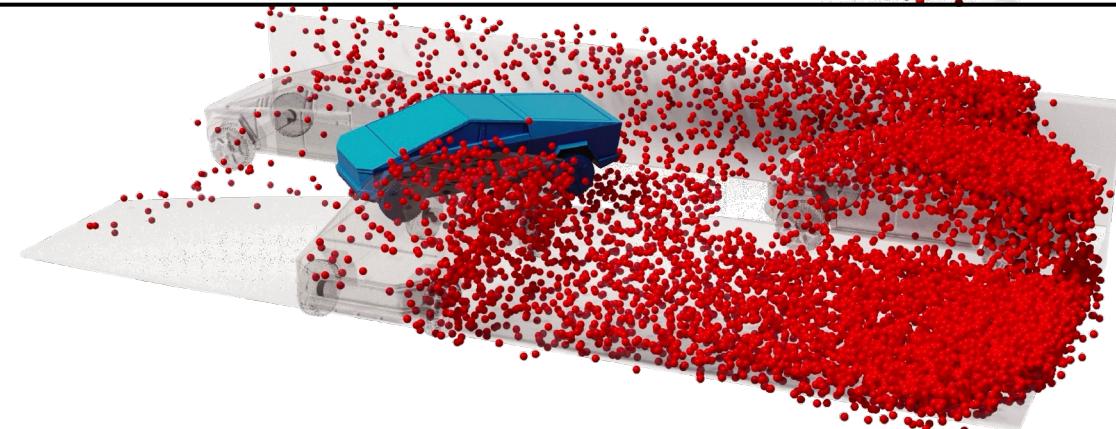
衝突無し



衝突無し

SPSRによる判定

0.56%の確率で衝突



衝突有り

36%の確率で衝突

# 最近の研究: SPSRを応用した法線方向の推定

[Sellan22] が提案した  
"uncertainty"指標:

$$U_{SPSR} = \int_{\Omega} \frac{1}{2} - |P(\mathbf{x} \in M) - \frac{1}{2}| d\mathbf{x}$$

提案: 符号付きのuncertainty指標

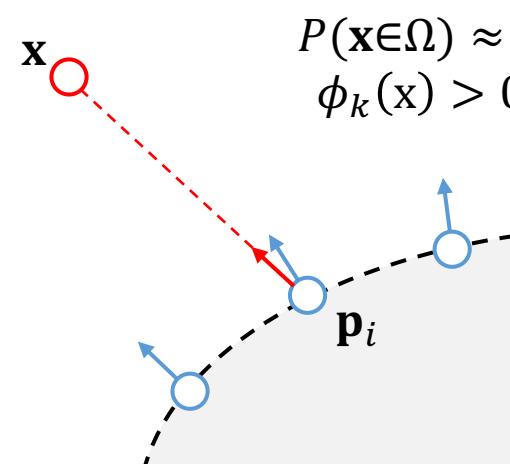
$$F = \int_{\Omega} \phi_k(\mathbf{x}) [P(\mathbf{x} \in M) - \frac{1}{2}] d\mathbf{x}$$

$$\phi_k(\mathbf{x}) = \sum_{n=1}^k \frac{(\mathbf{x} - \mathbf{p}_i) \cdot \mathbf{n}_i}{\|\mathbf{x} - \mathbf{p}_i\|_2}$$

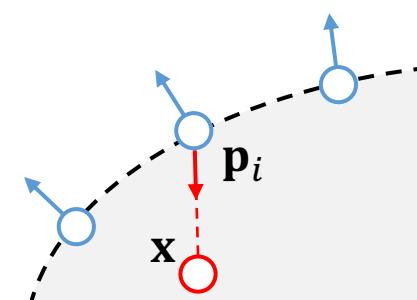
点 $\mathbf{x}$ の $k$ 近傍

$$G = \frac{1}{|S|} \sum_{\mathbf{p}_i \in S} (\mu_i - \hat{\mu})^2, \quad \hat{\mu} = \frac{1}{|S|} \sum_{\mathbf{p}_i \in S} \mu_i$$

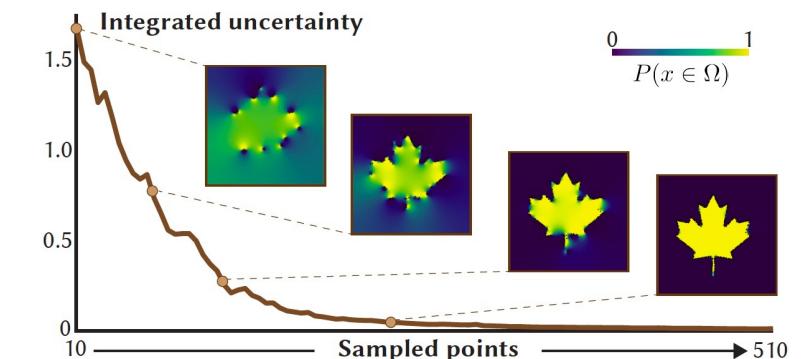
正規化項  $\mu_i$  における indicator 関数の値



$$P(\mathbf{x} \in \Omega) \approx 0 \\ \phi_k(\mathbf{x}) > 0$$



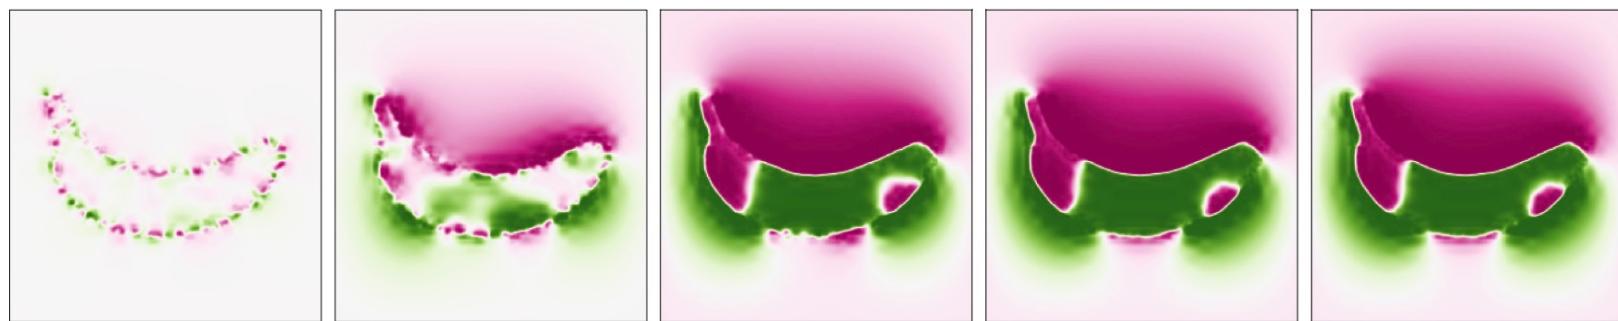
$$P(\mathbf{x} \in \Omega) \approx 1 \\ \phi_k(\mathbf{x}) < 0$$



点群の欠損/ノイズが減るほど、uncertaintyが下がる

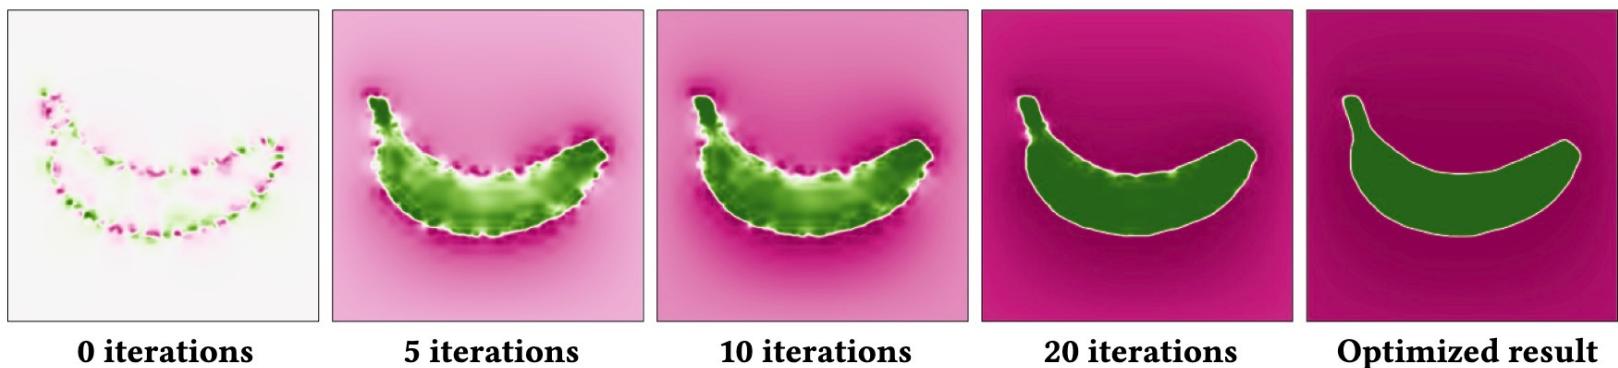
L-BFGSで最適化  
• 法線方向を極座標で表す

$U_{SPSR}$  の最小化



Random normals

提案法



0 iterations

5 iterations

10 iterations

20 iterations

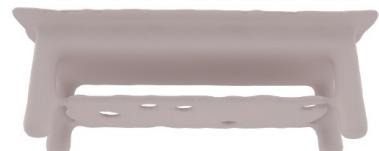
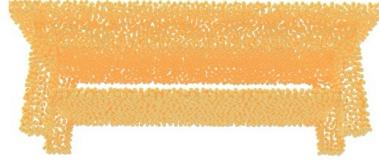
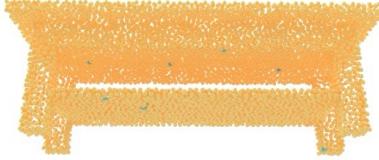
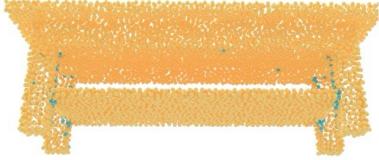
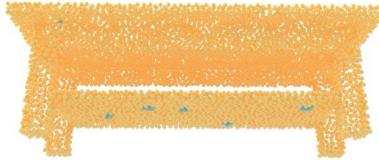
Optimized result

$NC = 99.15\%$

$NC = 98.91\%$

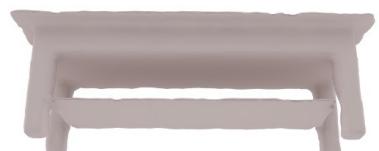
$NC = 99.61\%$

$NC = 100.00\%$



IPSR

[Hou22]



PGR

[Lin22]



GCNO

[Xu23]



Ours

# 最近の研究: 点群を直接エッジで繋ぐアプローチ

第1回Spatial AI勉強会

## Surface Reconstruction Using Rotation Systems

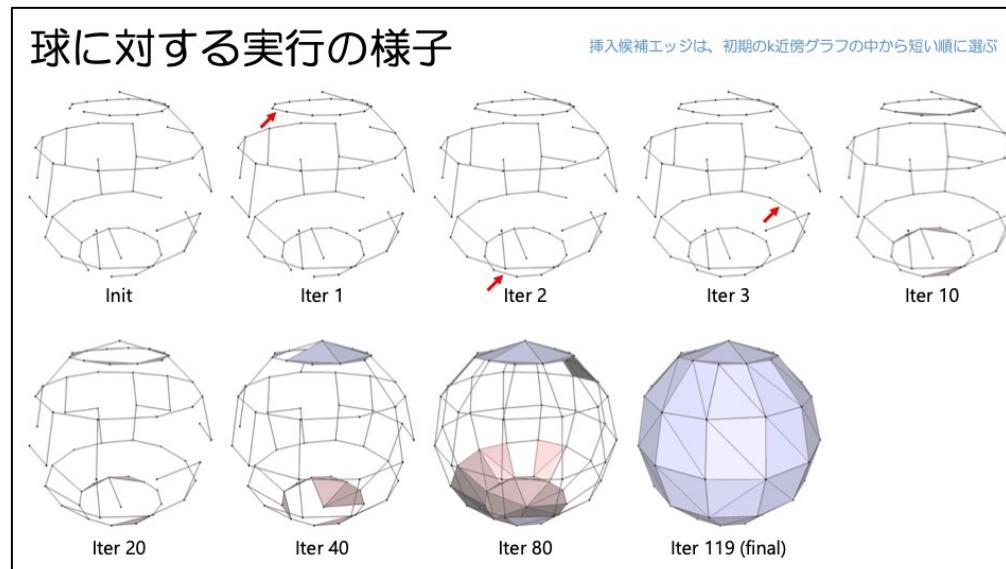
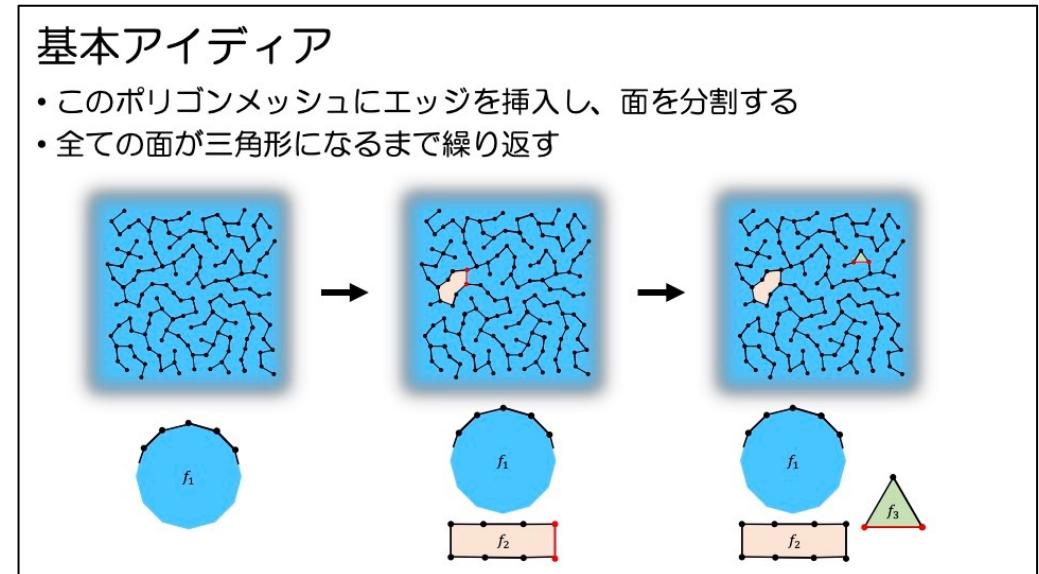
(SIGGRAPH Asia 2024 Journal Track)

Ruiqi Cui      Emil Tøftegaard Gæde      Eva Rotenberg      Leif Kobbelt      J. Andreas Bærentzen  
Technical University of Denmark Anker Engelunds Vej 10 Lyngby Denmark      Technical University of Denmark Anker Engelunds Vej 10 Lyngby Denmark      Technical University of Denmark Anker Engelunds Vej 10 Lyngby Denmark      Visual Computing Institute, RWTH Aachen University 1 Thiervald Circle Aachen Germany      Technical University of Denmark Anker Engelunds Vej 10 Lyngby Denmark  
[ruci@dtu.dk](mailto:ruci@dtu.dk)      [etoga@dtu.dk](mailto:etoga@dtu.dk)      [eror@dtu.dk](mailto:eror@dtu.dk)      [kobbelt@cs.rwth-aachen.de](mailto:kobbelt@cs.rwth-aachen.de)      [janba@dtu.dk](mailto:janba@dtu.dk)

Project: [https://cuirq3.github.io/projects/siga\\_24/](https://cuirq3.github.io/projects/siga_24/)  
Code: <https://github.com/cuirq3/RsR>  
arXiv: <https://arxiv.org/abs/2402.01893>  
YouTube: <https://youtu.be/9DEffN3pzng>

高山 健志 (CyberAgent)

2024年12月21日



# 参考サーバイ等

- State of the Art in Surface Reconstruction from Point Clouds [Berger EG14 STAR]
- A survey of methods for moving least squares surfaces [Cheng PBG08]
- Scattered Data Interpolation for Computer Graphics [Anjyo SIGGRAPH14 Course]
- An as-short-as-possible introduction to the least squares, weighted least squares and moving least squares for scattered data approximation and interpolation [Nealen TechRep04]

# 参考ページ

- <https://en.wikipedia.org/wiki/Metaballs>
- [http://en.wikipedia.org/wiki/Implicit\\_surface](http://en.wikipedia.org/wiki/Implicit_surface)
- [http://en.wikipedia.org/wiki/Radial\\_basis\\_function](http://en.wikipedia.org/wiki/Radial_basis_function)
- [http://en.wikipedia.org/wiki/Thin\\_plate\\_spline](http://en.wikipedia.org/wiki/Thin_plate_spline)
- [http://en.wikipedia.org/wiki/Polyharmonic\\_spline](http://en.wikipedia.org/wiki/Polyharmonic_spline)